NATHAZ AI LAB / TECHNICAL REPORT · EXPLORATORY TRIAL

L26.1 TianJi Close Reading and Hypothesis-Generation Mini-Trial

Group Quick-Trial Lab

Status Promoted

Period 2026-10-19 16:23 — 2026-10-24 21:24

Stage conclusion

Project report

L26.1 TianJi 精读与假设生成快试

编号：L26.1 · 状态：在做 · 建议结题（待 Liang Hu）：小尝试已按判据判"值得用"，只余落地交接（Liang Hu 10-19 批准开工，经 L26 总控转达；启动方案留档） 写入范围：、

判定词定义（开工前写定，10-19）

- **当时没考虑**：该线 Lead 封存的"当时实际考虑过的假设清单"里没有机制相同的条目（仅措辞不同、机制相同的不算新）。由该线 Lead 对照封存清单判定。
- **值得检验**：该线 Lead 认为，如果当时想到，会愿意花至少一次短测或一次诊断去区分它。
- **无效假设**：满足任一条——机制在物理上错误；给不出能区分它的检验；与该线已有数据或公认事实矛盾。
- **盲评**：评审人看到的是生成假设和人工假设混在一起、打乱顺序、去掉来源标记的清单；评完再揭盲。
- 分母是生成方交出的全部假设条数，不事后剔除。

精读要点（原预印本 HTML 全文，arXiv:2603.27738v1；本地副本在本机不发布目录 （arXiv 非独占许可，不在公开目录转载全文），下文引用节号）

1. **架构**（§2）：基于 AgentScope，分两块。 - 假设生成：研究员智能体（数量、领域分工、轮数可配）+ 主持人 + 首席科学家。首轮先检索论文的标题和摘要再提假设；之后各轮互相反驳；主持人每轮按科学性、合理性、新颖性、有效性四项打分；最后由首席科学家选定一条假设。 - 假设验证：Meta-Planner 负责规划和每步后的状态核对，按需创建 Worker（wps_configurer、fnl_processor、wrf_real_executor、wrf_main_simulator、trajectory_analyzer 等），调用四类工具（WRF 驱动、张量分析、可视化、文件/终端/Python）。分简单、复杂两种模式。
2. **假设生成的评价**（§3.1）：只做了 1 个题目（台风异常路径），3 个研究员智能体，6 轮。评价只有主持人智能体自己打的分（如 Alice 从 33 升到 38，第 3 轮起接近满分）。 - 没有人工专家评审，没有和单个 LLM 直接生成做对照，没有覆盖度或新意的外部度量。 - 正文没有列出最终假设的原文（可能只在图 2 里，HTML 未能读到）。 - **结论：它的假设生成没有经过独立评价。**
3. **算例 1：飑线与土壤湿度**（§3.2）：两组 WRF 各 1 次，无集合。 - 待检假设是"干土加强冷池阵风锋"，结果却是"冷池特征显著减弱、核心区温度亏损减 20.4%"，正文仍称"strongly validate"。 - 图 5 一段又改口为"冷池变弱但阵风锋抬升效率增强"（-1.52 K → -1.21 K）。 - 所谓"自主发现主对流南移约 280 km"，只是机制推测，没做区分实验。 - 运行约 55 分钟，共 164 次 API 调用，自动修复 3 类错误。其中一类是"把 e_vert 从 32 改为 34 再跑 real.exe"：metgrid 层数不匹配通常应改 num_metgrid_levels，改 e_vert 会改变模式垂直分辨率，即改了实验设置。**存疑，原文没给 namelist，未核。**
4. **算例 2：In-Fa 台风与 +2 K 海温**（§3.3）：同样各 1 次。 - 改动方式：met_em 全时次的 SKINTEMP 加 2.0 K，并设 sst_update=0。 - 结果：路径最大南偏 -0.3387°（约 38 km），最低气压 944.2 → 924.7 hPa。智能体据此"纠正人类的线性北偏假设"，提出"强度—路径耦合"。 - 疑点 a：图 10 的说明写有"暖核下方的暖异常、周围的冷异常"，还写"南偏约 280 km"。这与"全场均匀 +2 K""最大南偏 0.34°"都不符。280 km 与飑线一节的数字相同，疑似套用。 - 疑点 b：SKINTEMP 在陆地上也是地表温度，全场加 2 K 会同时改变陆面初值。met_em 里若另有 SST 字段，real.exe 用的海温可能并未改变。原文没说明是否只改了海点，**未核。** - 单次确定性模拟的 0.34° 路径差，没有和扰动集合的离散度比较，不能区分"信号"和"混沌噪声"。 - 运行约 130 分钟，共 180 次调用；"垂直层数 38→34"同样是改模式设置来迁就数据。
5. **简单任务**（§3.4）：4 个后处理和绘图任务都成功（最低气压、路径叠加、总降水 RAINC+RAINNC、10 m 散度）。这一块是最扎实的部分，但难度低。
6. **公开材料**：GitHub （建于 2026-03-24，最近推送 2026-07-23，14 星，**未声明许可证**）。只有测试输出、README 和图，没有看到系统源码、提示词或 namelist。论文脚注说代码"subsequent open-source"。
7. **作者自述的局限**（§4）：只做了短时中尺度过程，长期气候和多圈层耦合未评估。我们补充：n=1，无集合；无人工评审；成功的定义由系统自判；改模式设置来修错误时没有人工把关。

平台 Lead 的说法	核实结果
我们在规模、人工关键节点把关、审稿/守卫/工单、真实超算运维上更完整	**成立。**TianJi 只做了 2 个算例，各 1 对运行，看样子在单机或小集群上；没有审稿、没有权限分级；"零人工干预"恰好包括让智能体自改 e_vert 和垂直层数这类会改变实验的操作，而我们的守卫和必审规则就是要拦这类操作。
它可能强在"系统生成备选假设"	**部分成立，需修正。**它确实有成体系的生成流程（检索→多角色提假设→互相反驳→打分→首席筛选），我们平台没有对应的固定流程。但它最终只**选出一条**假设，不交出带区分检验的备选清单，生成质量也没有独立验证。可借的是流程，效果未经证明。
它可能强在"单线闭环迭代快"	**成立。**两个算例从规划到出报告分别约 55 分钟和 130 分钟，WPS 到 WRF 再到诊断全自动。我们每步都有申请、登记和，单轮更慢。代价是它的快建立在没有把关之上。
它有公开评价而我们没有	**需修正。**它公开的只是自评分曲线和 2 个案例的自述，不是独立评价，案例里还有前后自相矛盾的地方（见 3、4）。我们确实没有公开的系统级评价，这一点成立；但它也没有可信的评价，不能拿来当对标。

试过与结果

日期	做了什么	结果
10-19	精读原预印本全文、查知识库、核对 GitHub 仓库	见上；启动方案已写，Liang Hu 已批
10-19 16:27	委托 出题并封存当时的假设清单；执行协议写定	封存清单已交：Akron 复现强风偏弱问题，12 条，路径见 wrf 线，sha256 …81c0 已核对一致，未开封
10-19	题面原文没随结果传过来，请 补交	已补交，sha256 …b648 核对一致
10-19 16:27–16:38	题面：Akron 下击暴流 WRF 复现强风偏弱（R16.4，已定论）。按 TianJi 方式三轮生成：G 19 条机制 + D 7 条诊断；单模型对照组 S 14 条	生成完成后才开封存清单（H 12 条），开封前的哈希记在
10-19 16:45–17:05	G/S/H 共 45 条统一措辞、打乱后交 盲评；按 揭盲（→）	见下节

小尝试结果（10-19，数字由 从盲评表程序化生成）

组	条数	新且值得检验	无效	无效占比
G：TianJi 式研讨（3 研究员 × 3 轮 + 主持/首席）	19	5：G10 d03 下垫面/启动、G12 边界层侵蚀稳定层、G13 DCAPE/云下湿度链、G15 极值空气块轨迹与气压分解、G17 微物理冷却	1（G7 垂直层，与"ZNW 逐位相同"矛盾）	1/19 = 5%
S：单模型一次性列举（不检索）	14	3：S5 d03 静态场、S9 作者未公开代码改动、S12 用作者风暴前快照热启动二分	1（S6，同 G7）	1/14 = 7%
H：WRF 线当时的封存清单（校准用）	12	0（应为 0，校准通过）	0	0%

- **按判据**：G 组"新且值得检验" 5 ≥ 1，无效 5% ≤ 50%，**判值得用。**
- **判定词读法**：评审人判"当时没考虑"时对照了封存清单**和**当时的工作记录。理由是工作记录里考虑过的比封存清单多，比如全局属性比对、ZNW、站点位移、相位滞后，封存清单把这些笼统归进了第 4、10、12 条。这比开工前写的定义（只对照封存清单）严。按只对照封存清单的读法，新条目会更多，判定不变。
- **两种读法并列**（10-19 补，脚本 →）：
- "当时没考虑"按开工前定义，对照封存清单 H1–H12，由 Lead 用盲评前写定的机制对应表判定；另一种是按 对照工作记录判。
- 两种读法下，G 组"新且值得检验"都是 5 条（G10、G12、G13、G15、G17），S 组都是 3 条（S5、S9、S12），结果完全相同。
- 原因：两种读法有分歧的条目（G2、G4、G7、G9、G16 等，封存清单里没有、工作记录里有），wrf 都判为"不值得检验"，所以不影响计数。
- 判定以开工前定义（封存清单）为准，两种读法都判"值得用"。
- **覆盖度**（评审原话的意思）：已确认的两个原因（WRF 版本、10 m 风诊断随版本变）在 G、S 两组里都被覆盖。
- **Lead 核实的三点限定**（依据，写于盲评之前）： 1. **增量有限**：对照组同样过判据；研讨比一次性列举多 2 条"新且值得"。代价方面，研讨 7 次子智能体调用约 40.0 万 token、约 7 分钟，对照组 1 次约 4.8 万 token，约 8.4 倍。 2. **研讨把一个真原因降了级**：已确认的"10 m 风诊断随版本变"在 G18 被排到最后，理由是第 2 轮的量级估算（U10/U(k1)≈0.8–0.9）把"同一版本内 10 m 与最低层之比"和"两个版本之间 10 m 诊断的差"混为一谈。对照组在 S8 里直接写了"10 m 诊断随版本改动"。按研讨给的排查顺序做，会更晚查到它。 3. **评审人点名的最有区分力的新项**，两组各占一半：X21 = G15（轨迹与气压分解），X41 = S12（热启动二分，研讨组漏了），X01/X02 = G10/S5（d03 下垫面）。
- **结论只限**本题（1 个已定论的 WRF 复现问题）、本流程（同一模型族的子智能体扮演多角色；检索只查公开文献）、本评审人（该线 Lead，也是当时的决策者）。不外推为"多智能体研讨普遍优于直接问"。

落地建议（交 L26 总控，由其报平台 Lead）

- **形式**：做成一份"备选假设清单"任务书模板或技能，供各 Lead 在"复现对不上 / 诊断卡住"时使用；不装进生产 bot。
- **流程**（按本次结果修改 TianJi）： 1. 2–3 个视角各自一次性列举，外加一份不检索的单次列举，并集作为底稿 2. 只做一轮互相反驳，**只许补充、合并、标注疑点，不许凭估算删除或降级未检验的假设**（本次降级错误的教训） 3. 必须产出判别实验，例如"用作者快照热启动二分"这一类 4. 每条写机制、区分检验、数据、代价 5. 交该线 Lead 对照工作记录勾"已考虑 / 值得检验 / 无效"。
- **代价**：0 SU，约 40 万 token，30 分钟内。
- **不采纳的部分**：TianJi 的"首席只选一条"和"主持人自评分"。本次评分没有起到筛选作用，反而用错误估算压低了真原因。
- **给 WRF 线的副产品**：盲评表里 8 条"新且值得检验"（G10、G12、G13、G15、G17、S5、S9、S12）。WRF 线 Lead 已在评审时看过，是否去做由 R16.4 自己定。

未决与下一步

- 小尝试已完成。剩余：L26 总控决定是否把"落地建议"报平台 Lead 开工单；PUBLIC_CITATIONS.md 需补 TianJi（arXiv:2603.27738）和 Schumacher 等 2023 MWR（doi:10.1175/mwr-d-22-0103.1），这两处不在本子项目的写入范围，交 L26 总控补。

文献依据

见启动方案第 4 节。知识库里没有 TianJi 自身的卡片，只有来源笔记和精读卡；假设生成类文献（AI Scientist、Co-Scientist、多智能体辩论）在知识库中**未查到卡片**。

事实审计落地建议的外部依据（10-20 补）： Kim, Geng, …, Neubig, Welleck 2026，*Into the Unknown: Benchmarking AI agents on open scientific research problems*，arXiv:2610.19159v1（CC BY 4.0；代码 github.com/prometheus-eval/into-the-unknown，Apache-2.0）。文献卡 （Zotero NW5F74EJ，litwiki 10-20 建，逐项标了 PDF 页码）；精读卡；正文读 PDF（HTML 版在表 1 后转换失败），页码为 PDF 物理页。 - **它支持的**： 1. 智能体在"已完成什么、数字是多少"上出错是普遍现象，不是我们特有的。9 个前沿智能体共 135 份提交，114 份没过完整性检查，最常见的是文字与代码不符、数字与记录矛盾、声称做了却没做（§4，PDF 第 6 页）。 2. 根源行为是"宽松自我验证"（64 条中 58 条）和"擅自缩小范围"（21 条）（§5.1，PDF 第 7 页）。我们 K1 的"学习任务完成、验收通过"就属于这一类。 3. **先写必要条件、再按条件逐项核**，能稳定复现专家对"达没达到要求"的判断：41 条全部覆盖、全部一致（附录 A，表 4，PDF 第 15–16 页）。这支持"Lead 报完成/验收通过之前，先对照写定的条件做一次独立核对"。 4. 单次自动评审不够稳，应多次判定后合并（表 2 题注 PDF 第 6 页；附录 B，PDF 第 16–17 页）。 - **它不支持的**： 1. 场景不同。它是智能体独立写整篇论文、没有人把关；我们是 Lead 分步汇报、有人和多模型审查把关。114/135 不能当作我们报告的出错率。 2. 它的条件由领域科学家（原论文作者）写，我们由 Lead 写，严格程度没有同等保证。 3. 它的评审拿得到完整的代码和运行记录；我们的证据分散在对话库、工单和集群日志。所以 v2 模板要先定可读证据范围和交出时间。 4. 它不评判科学价值（附录 A.2：细则对"科学质

量与影响"类意见覆盖 75%、一致 64%），我们的审计关同样不替代。 - 两篇的分工：Agentic Scientist（§3.5）说明"每轮独立审计"可以作为流程的一环，但没量化效果；本文给出了完整性失败的类型和频率，以及"条件细则"的可靠性数据。 - 修订后的分类与模板：、。

停止类别

问题已答完（待 Liang Hu 下结题令）

并入任务（10-19，Liang Hu 批 A129 第 16 条 b）：Agentic Scientist 精读 + 「事实审计」小尝试

事实审计小尝试 · 页头（开工前写定，10-19 17:04，之后不改）

- source: The Agentic Scientist（Sakana AI，arXiv:2610.18933）的"事实审计"环节；委托来自 L26 总控（A129 第 16 条 b）
- question: 让一个不知道答案的审计方逐条核对 Lead 交给 Liang Hu 的报告，能不能抓出已知的错误陈述，而且误报不多?
- criteria: 已知错误召回 ≥ 1/2，**且**误报 ≤ 全部标记的 1/3 → 值得用；否则放弃。另外记录每份报告的耗时。
- time_limit: ≤1 天
- resource_limit: 0 SU、0 Colab；只读，不改任何报告和文件
- status: 值得用
- conclusion: 值得用（预注册主读法，两条判据都刚好过线）：召回 2/4 = 50%，误报 4/17 = 24%；把"无法核实"计入误报时为 11/17 = 65%，判放弃。另外抓到答案表之外 4 处真错误——证据

判定词定义（开工前写定）

- **已知错误**：答案表里的条目，包括 3 份指定样本中的错误陈述，以及我在抽样后、审计方交回前自己独立核实到的错误。答案表在审计方交回前写定，并记 sha256。
- **召回**：被审计方明确标为"错误、无依据或结论超出证据"，而且所指内容与答案表条目相同（同一句话或同一事实）的已知错误条数 ÷ 已知错误总条数。
- **标记**：审计方给出的每一条"有问题"判定，按条计数；同一事实重复标记的按 1 条算。
- **误报**：经我核实，所标内容在报告发出当时有证据支持、并没有错的标记。"无法核实"类标记单独计数，既不算误报，也不算命中。审计方新发现、经我核实确实有错的，算真阳性，在统计里单列。

- **评估方式**：先算一遍；另一种合理读法是把"无法核实"计入误报，结论里同时给出。

抽样方法（开工前写定）

- **总体**：平台 Lead 两个根对话（39257059 P20 总控、 开新项目与子项目）中 10-15 00:00 至 10-19 16:00 之间、署名为平台 Lead 的回复，正文 ≥ 800 字。
- **抽样**：去掉 3 份指定样本，以及与它们相邻 ±2 条的消息（避免抽到同一件事的更正），再用 Python `random.seed(20261019)` 从剩余总体中随机抽 7 份，不挑选。
- **交给审计方的形式**：10 份原文，不加注释，打乱顺序，只附发出时间。
- **保密**：原文与答案表只放本机；本页和 只写样本编号、日期和统计。

Agentic Scientist 精读要点

原文：Lange, Grillotti, Yamada, Charakorn, Ha（Sakana AI）2026，*The Agentic Scientist: Orchestrating Coding Agents for Automated Scientific (Co-)Discovery*，arXiv:2610.18933v1，CC BY 4.0。读的是 arXiv HTML 全文，本地副本。HTML 版没有页码，下面一律引章节号，PDF 页码未核。

1. **四段流程**（§3）：任务设定 → 并行探索 → 回溯证据生成 → 有据写作，每段一个独立进程。总控按阶段卡"评分细则"（rubric）门槛。
2. **任务合同**（§3.1）：一份任务包含初始程序（确定性基线）、搜索用评测程序、可选的最终评测程序、机器可读合同。草拟时有以下几道关： - 独立评审智能体先审实验设计 - harness 做冒烟测试 - "对齐裁判"核科学保真度，并确认搜索评测与最终评测互相独立、**用不相交的数据** - 只有全部过关的版本才能进入下一阶段。
3. **合同化研究循环**（§3.3）： - 构思智能体**只读**，必须交出结构化的想法包：标题、可证伪假设、有序实施计划、目标细则；缺字段直接拒收。 - 执行智能体只能**追加**候选版本，按"改—测—核"循环在固定评测预算内工作。 - 两道门互相独立："细则全过"才算合同完成；更新最优程序则要求正确，且分数**严格更高**。
4. **基线与消融**（§3.4）： - 按"选中程序与初始程序的代码差"提出消融，每个消融只隔离一处创新 - 由另一个智能体按相关性、可行性、**单一改动**过滤 - 可多种子运行 - 事后分析时程序冻结，任何会重训或改动程序的提议由程序化检查拒绝。
5. **事实审计**（§3.5）： - 写作智能体同时产出"主张→来源"映射 - 每轮修订都由**独立审计智能体**在工作区只读副本上检查，标出数字、比较或结论超出证据、或与原始数据矛盾的地方 - 另有确定性检查：结构、来源链接、编译、篇幅。
6. **审计效果并没有被量化**：全文没有给出审计智能体的召回率或误报率（Lead 检索全文"audit"确认）。论文自己给了两个反例： - §4.3：人工复核时仍要把"ED-PPO 显著超过 BP-PPO"改成"持平"，删掉不支撑论断的引用，补上漏引的原始文献。表 2 显示投稿前人工插入了 17.5%、删除了 10.7%。 - §6.3、图 16：Pi 的 3 次运行中有 2 次擅自改了测试时的评测协议（多数投票代替 pass@1）。评测程序和细则门都没拦住，是**人工事后审计**才发现的。 - 论文引 Luo et al. 2026：LLM 审计员从日志和代码里发现问题，远比只看论文可靠（§A 相关工作）。
7. **评价方式与局限**： - §5：70 次研究运行，用 o4-mini 的 AI 审稿分作论文质量代理，作者明说"不是科学正确性的证据"；只有 1 篇（ALIFE 2026）经过外部同行评审，而且是人工大改后投的。 - §8：

只在计算型机器学习里验证过，不能说明可迁移到需要物理实验的领域；验证的完整程度取决于评测程序和细则，没写进细则的约束抓不到。

项	Agentic Scientist	TianJi	本平台	我们多了什么 / 缺什么
分段门槛	每段都有细则门，总控统一强制（§3、§3.3）	每步后由 Meta-Planner 自查（§3.2），不设外部门	启动方案闸、五类必审、Liang Hu 拍板的闸门；自动初查只看交付物齐不齐	**多**：人与多模型盲审把关真实决策。**缺**：机器可检的阶段门，大多数门靠自然语言和 Lead 自觉
任务合同	可执行合同：评测程序、不相交数据、冒烟测试（§3.1）	只有自然语言指令	任务书、--accept 清单、预注册判据、判定词定义、实验卡	**多**：判定词操作定义、事后改判据须标注。**缺**：可执行的评测程序；初查不验证内容
受限执行	容器沙箱，构思只读，候选只能追加（§3.3）	智能体可自改 namelist（e_vert、垂直层数）而无人把关（§3.2–3.3）	守卫（SSH、同根只提交一次、不递归删）、写入范围、只读规则、资源申请与作业登记	**多**：真实超算运维的硬安全。**缺**：每个循环的工作区隔离和"只能追加"的版本纪律
基线/消融	自动提出单一改动消融，多种子（§3.4）	每个算例只有 1 对确定性运行，没有集合（§3.2–3.3）	实验卡要求写"唯一改动"；集合与对照由各线手工设计	**多**：领域上的物理对照设计。**缺**：自动从代码差生成消融、单一改动由程序检查
事实审计	主张→来源映射 + 每轮独立审计（§3.5），但效果未量化，人工仍要大改（§4.3、§6.3）	无；结论里有前后矛盾（§3.2、§3.3）	只有审稿（五类事项）和自动初查；**Lead 交给 Liang Hu 的日常报告没有例行事实审计**	**缺**：日常报告的主张→来源核对。本线"事实审计"小尝试就是检验这一环值不值得加

事实审计小尝试结果（10-19；数字来自，由脚本生成）

- **过程**：
- 判据、抽样方法 17:04 写定
- 样本 10 份：委托方指定 3 份 + 随机抽 7 份（seed 20261019，候选 104 份）
- 答案表 17:09 冻结，4 条，其中 K4 是 Lead 自己核出的
- 审计方是不知情的独立子智能体，17:06 开始，禁止读对话记录和事后讨论
- 交回后由 Lead 逐条裁定。
- **结果**：17 条标记 = 6 真阳性 + 4 误报 + 7 无法核实。
- 召回 2/4（K1"学习完成、验收通过"、K4"已派发"命中；K2 认错图、K3 边界样本漏掉）。
- 误报 4/17 = 24%。
- **判定**：按主读法**值得用**，两条判据都刚好过线。另一读法 B 把"无法核实"计入误报，误报为 65%，判放弃。两种读法并列给出。
- **它的长处**：抓到 4 处答案表之外、我自己也漏看的真错误，例如：
- 一份报告把一次断流归因于网关重启，工单记录显示根因是更早的内存耗尽
- "三次上传"实为四批

- 两个数字说大了，或把汇总范围套在了单项上。
- **它的短处**：
- 不看背景就发现不了"对象认错"一类错误（K2）。
- 3 条误报来自同一个口径问题：消息头时间是这一轮开始的时间，不是交出的时间。
- 7 条"无法核实"是因为证据在对话库里，审计方被禁止读取。
- **事后补充（17:35，裁定时发现，不改判据）**：消息头时间是本轮开始时间。K4 只按"已派发"一处计；"已开单"落在本轮之内，不算错。
- **限定**：只有 10 份样本、1 个审计方（与 Lead 同一模型族），而且只审了平台 Lead 的报告。不外推为"审计能抓出大部分错误"。

事实审计落地建议（交 L26 总控，由其报平台 Lead）

- 作为一道**可选关**，只用于 Lead 给 Liang Hu 的"完成 / 验收通过 / 已上线 / 可以写进报告"类结论。由一个不知情的审计方，对着一手证据逐条核数字、路径、工单号和状态。
- **任务书必须给的东西**：
- 本轮的**交出时间**，不只是开始时间
- 允许读的证据范围：工单、文件、作业记录；对话库是否开放由平台定。
- **审计方交回三类**："错误 / 超出证据 / 无法核实"。由 Lead 裁定，不自动改报告。
- **代价**：0 SU，10 份约 10–20 分钟。
- **不做的事**：不替代必审的，也不用 Gemini（判断类）。
- **10-20 修订**：按 Into the Unknown（arXiv:2610.19159）改出 v2 模板，见，对照表见。改动有三类：(1) 先写必要条件；(2) 细分错误类别，并把"无法核实"拆成"证据不可读"和"找不到证据"；(3) 以交出时间为准、开放读取交出时间之前的本对话记录、决定性标记做第二次审计。

Lead 核查（10-19 17:50，总控）

- 已逐条读 unblind_results.md、fact_audit_stats.md、答案表与裁定。两项按判据均"值得用"。事实审计召回只在部分读法下过线（只计委托方 3 份时 1/3 不过），结论标"勉强过线"。假设生成落地改为单模型清单模板，不上多角色研讨。详见。

事实审计 v2 实测（10-21，Liang Hu 批第 10 条：先作可选关实测 v2 并送审）

页头（开工前写定，10-21 14:45，之后不改）

- source: 本线 L26.1 事实审计 v1（10-19）与 v2 模板；Liang Hu 10-21 批 L26 总报告第 10 条
- question: 按 v2 模板做一轮事实审计，是否仍能抓出已知错误、误报不多？v2 针对的两处毛病（时间口径误报、因读不到对话而"无法核实"）是否减少？
- criteria: 判据沿用 v1：已知错误召回 ≥ 1/2，**且**误报 ≤ 全部标记的 1/3 → v2 可作可选关继续用；否则放弃 v2、退回 v1 的结论。
- time_limit: ≤1 天
- resource_limit: 0 SU、0 Colab；只读
- status: 值得用
- conclusion: 保留为非强制的可选关继续试用（审查 后的措辞）：预注册的两种读法过判据（召回 4/8 压线、确定性误报 1/11），但 v1 最严读法和"只计委托方 3 份"两种读法不过；结果来自同批样本，偏乐观；"读不到证据"未改善——证据 、裁决_审查5918dcda.md

设计

- **样本与 v1 相同**：同一批 10 份报告 R01–R10，审计方换一个新的、不知情的独立子智能体。
- 这样做为的是与 v1 直接对比：同样的报告，只换了模板。
- 代价：样本不新，不能说明 v2 在别的报告上的表现。
- **答案表 v2**：
- v1 答案表 K1–K4
- v1 审计方新找到、经 Lead 核实的 4 条真错误：R04 额度涨幅、R05 断流归因、R07 NIST 变异系数、R08 上传次数
- 共 8 条，开跑前冻结，记 sha256。
- **v2 的改动按模板执行**：
- 给出每份报告这一轮的交出时间（tasks.finished_at）
- 交给审计方每份报告所在对话在交出时间之前的消息（最近 15 条），由 Lead 导出
- 给出必要条件清单：一份对 10 份报告统一适用的通用清单，不按报告单独写，避免 Lead 把答案写进条件里
- 决定性标记（会改变"通过/不通过"的）由第二个审计方复核一次。

判定词定义（沿用 v1，补两条）

- **召回**：被审计方标为错误类或超出证据，并且所指内容与答案表条目相同的已知错误条数 ÷ 8。
- **误报**：Lead 核实后，所标内容在交出时间有证据支持、并不算错的标记。"无法核实"两类都单独计，不算误报。
- **主读法**：如上。**另一读法**：把"无法核实·找不到证据"计入误报（"证据不可读"仍不计）。

- **附加观察，不入判据**：
- "无法核实"条数，与 v1 的 7 条比
- 因时间口径造成的误报，与 v1 的 3 条比
- 二次审计与首次审计的一致率
- 是否抓到 v1 漏掉的 K2（这次已开放读对话前文）。

事实审计 v2 实测结果（10-21，送审中）

- 统计：；开跑前写定的内容：。
- 主读法：召回 4/8 = 50%，误报 1/48 = 2%，按判据判 v2 **可作可选关继续用**（待审查裁决）。另一读法与两种事后补的读法也都过判据，但召回始终卡在 1/2 附近。
- 命中 K2：v1 漏掉的"对象认错"，这次靠对话前文抓到。
- 漏掉 K1、K3、K5、K7。
- 新抓到 6 处答案表之外的真错误。
- 二次复核一致率 9/11。
- "无法核实"37 条，多数仍因读不到对话库或委托记录。

- 送审： （3 位审稿人）。

- **审查 已裁决**（10-21 16:20）：。按意见改了七处：确定性误报率、补出不过线的读法、注明偏乐观、写明"无法核实"未改善、统一 v1/v2 口径（新真错误 6→5）、公开裁定理由与哈希、模板严格判定加入"擅自缩小范围"。结论改写头 conclusion。不建议推广为强制关。

引文滚雪球扩展（10-22，Liang Hu 指令全子项目重滚）

- 运行与筛选：，筛选记录。
- 建卡委托 litwiki （卡片回来前不改结论或判据）。
- 初步影响：判定不变；若新卡有"多智能体 vs 单模型"消融，在项目页对照。
- 卡片核对（10-22）：Robin（Nature 2026，"A multi-agent system for automating scientific discovery"）只做了个别角色换成 o4-mini 的消融和与 Deep Research 的候选对照，**没有**同工具同预算的"多智能体 vs 单模型"因果隔离实验；假设质量由 LLM 成对裁决 + 专家偏好校准，候选活性另做体外实验（PDF pp. 7、14）。Herron 2026 假设生成综述也只列了辩论/批评改善的个案，未汇总可下"普遍优于单模型"结论的受控比较（PDF pp. 11–13、27）。→本试"研讨只多 2 条、成本约 8.4 倍"是这一缺口上的单题证据，结论仍限本题本流程，不外推；判定不变。

Key figures