NATHAZ AI LAB / 技术报告 · 探索试验

L26.9 Nature Review Studio 审稿覆盖率快试

分组 快试实验室

状态 放弃

起止 2026-10-19 22:26 — 2026-10-26 12:17

阶段结论

项目报告

L26.9 Nature Review Studio 审稿覆盖率快试

启动方案：（10-19 22:40 交） 闸门：**已放行**——平台 10-19 执行 `pplan approve L26.9 A149`（依据 Liang Hu 10-19 22:4x 原话）。 成果去向：T34.2「论文评审」Lead。

最新：NHESS 子样本结果（10-26 12:2x，Liang Hu 批 A293；建议结题（待 Liang Hu））

部分	判据（10-19 写定，未改）	NHESS 子样本结果	与 10-21 主样本对比	判定
12 轴检查清单	Δ覆盖率 ≥10 个百分点	A 27.3% / B 29.2%，Δ +1.9，95% 区间 [−1.0, +4.7]（10 篇 314 单元）；只看主要意见 Δ +3.6 [−2.4, +9.5]；含部分覆盖 Δ −0.1	主样本 Δ +0.1 [−2.2, +2.4]；合并 20 篇 747 单元 Δ +0.8 [−0.9, +2.6]	**放弃（无实用增量），同向**
回复动作字典	可标注 ≥85% 且 κ≥0.6	78.7%（211/268），κ 0.73	主样本 84.3%；合并 80.1%（286/357）	**放弃，同向**
manuscript 起草	用字典组同向率 ≥60%	未在 NHESS 重做（见下方"Decision I made"）	主样本 70%（用字典）/ 75%（不用）	沿用主样本结论

- 判定可靠性：两判逐对 κ 0.80–0.98；119 处分歧由 Lead 盲裁；只用交集、并集、单个判者四种读法 Δ 都在 +1.8 到 +2.3 之间，区间上界都 ≤ +5.0。模型意见无效条目两组都是 0。
- 单篇只有 H8（保险损失模型与气象损失指数，62 单元）B 组高 11.8 pp；其余 9 篇在 −3.7 到 +6.7 之间。单篇差异不作归因。
- NHESS 的定位与局限：地学/灾害期刊，审稿意见公开讨论制（RC/AC 全公开，CC BY），与 WES 同属 Copernicus 体系，所以两个子样本审稿文化相近，不算真正独立的"另一种期刊"；10 篇以欧洲风暴损失、热带气旋、对流大风、龙卷气候、保险/风险为主，**结构风工程（风荷载、风致振动、构件易损性）论文一篇都没有**——NHESS 本身很少发这类文章，检索到的 229 条候选标题里也没有；2016 年前的旧讨论系统不可用，年份实际为 2017–2025；N7 森林风倒、N10 基础设施两层没有合格候选，按 11:45 补定规则从合并池补抽 2 篇（去掉这 2 篇的 8 篇读法 Δ +2.3 [−0.8, +5.6]，结论不变）；H7 的作者回复在 zip 附件里未取，字典部分少 44 单元。
- 结论限定：本两个样本（Copernicus 两刊 18 篇 + Nat Commun 2 篇）、本模型（Claude 同一模型族生成与判定）、本提示。不外推到结构风工程期刊或别的模型。
- **Decision I made**：NHESS 子样本不重做 manuscript 起草检验——字典已在标注一关两次不过线，且主样本里用字典没有带来起草增益，重做 40 份起草也改不了"字典不引入"的判定——错了的代价：如果字典在风灾论文上对起草有帮助，这次没测到；需要时可用已拆好的 268 条作者回复补做，约 manuscript 40 次起草。
- 证据：、；校验码 、。原文、审稿意见、判定明细只在本机不发布目录。

结论（10-21 15:3x，主样本，按开工前判据）

部分	判据	结果	判定
12 轴检查清单	Δ覆盖率 ≥10 个百分点	A 26.5% / B 26.6%，Δ +0.1，95% 区间 [−2.2, +2.4]（433 单元）；10 篇中 4 篇 B 高、6 篇 B 低	**放弃（无增量）**
回复动作字典	可标注 ≥85% 且 κ≥0.6	84.3%（75/89），κ 0.74	**放弃（差 1 条未过线）**；缺 4 类动作，补上后可能过线，但下一条显示字典对起草无增益
manuscript 起草同向回复	用字典组同向率 ≥60%	用字典 70%（14/20）；不用字典 75%（15/20）；判者一致 100%	**按判据过线**，但增益不来自字典；主要意见只有 6–7/12 同向，毛病是"过度答应"
"真实数据蒸馏"卖点	（核查，无判据）	只有汇总计数和校验码可查；分类靠关键词正则	无法核实

结论限定：本样本（WES 8 篇 + Nat Commun 2 篇，风能/大气/流体为主，结构风荷载类少）、本模型（Claude 同一模型族生成与判定）、本提示。判定"无效意见"的指标两组都是 0，判者偏宽，不作依据。建议去向：不把 12 轴清单装进，不把字典装进 manuscript；只把"起草回复时提醒：作者可以有理由不做，先判断是否该做"这一条教训交 T34.2「论文评审」Lead 参考。属"出口 X2：只存格式"。

过程状态（10-21 14:4x）

- **参照来源改为 b（Liang Hu 10-21 定）**：Wind Energy Science 公开审稿 8 篇 + Nature Communications P1、P2（审投稿原版）。Liang Hu 原话「好的，全部按你建议的开始执行。注意如果需要文献的话最好先寻找文献。由于这是快试，尽量不使用deep research」。状态改回在做。
- 选样规则 10-21 14:42 写定：；意见拆分规则 14:43 写定；冻结文件 sha256 见。
- 第 1 批（P1、P2）：真实意见单元冻结 P1 35 个（sha256 …）、P2 54 个（…）；12 份模型审稿意见已生成；盲化对照表 sha256 23c0b3e57bde8f7285f97dc35cc093a1250231e94285b5ea82d879180f9b5a7f（判前记录）。
- 第 2 批（W1–W5）盲化对照表 sha256 dad3095cc166aeea10d54ca4f4bf01ed6f5e7b8d51dff47fe3a5c3f5065b8f81（10-21 判前记录）。
- 第 3 批（W6–W8）盲化对照表 sha256 9d935fb9262734a8f39225178037f81630de1717101e19c75b7ec33a2da5b31f（判前记录；10-21 判定前修正盲化脚本：两份审稿意见里的子弹点被误拆成独立条目，改为并入所属编号条目后重盲化，旧对照表作废未用）。
- **偏离（如实记录）**：①回复动作标注由两位独立子智能体完成，未按方案由 Lead 亲标其一（Lead 只核统计与标不上的条目）；②方案写"全部判完才打开对照表"；第 1 批对照表在第 1 批判完、第 2 批尚未生成时已打开（Lead 先看了 P1/P2 的中间结果）。后续批次的分歧裁决仍在不知组别的情况下做，生成与判定提示词未改。

- 已做（都属"读材料"）：
- 仓库静态核查：GitHub API 和 raw 文本，副本与 sha256 在，不发布
- 3 篇样本论文的 PRF 链接核实并下载到 （不发布）
- 文献检索。
- 没做：任何审稿生成、判定、委托 bot。

已定决定

- 样本：P1 城市云增强 LES（doi:10.1038/s41467-026-68986-0）、P2 垂直轴风机变桨（doi:10.1038/s41467-024-46988-0）为主样本，都审 Research Square 投稿原版；P3 海上风电尾流（doi:10.1038/s41467-026-68655-2）无预印本，只作补充。待 Liang Hu 在方案 §7 确认。
- 仓库文本与 PRF 原文不进公开目录，公开页只放设计、统计、结论。

试过与结果

日期	做了什么	结果	证据
10-21	检查清单覆盖率（10 篇：WES 8 + Nat Commun 2；433 个真实意见单元；每篇两组各 3 份、共 60 份模型审稿意见；两判盲评 + Lead 盲裁，κ 0.75–0.94）	主读法 A 26.5% / B 26.6%，Δ +0.1 个百分点，95% 区间 [−2.2, +2.4]；含部分覆盖 Δ +0.1；只看 major 单元 Δ −0.5。按 §2.5 判据：**无增量 → 检查清单放弃**	
10-21	回复动作字典标注（P1、P2 89 条作者回复，两位独立标注者）	可标注 84.3%（75/89），κ 0.74；判据 ≥85% 且 κ≥0.6 → **差 1 条未过线**；缺"只回复不改稿""删减正文""为已有结果补图""部分回应"四类动作	
10-19	静态核查「1287 份真实 PRF 蒸馏」	可查的只有聚合计数和源文件校验码，语料未发布；12 轴与严重度由关键词正则打标，与 README"人工归类""≥5% 标 major"的说法不符；"21 种回复动作"表中实列 20 种	启动方案 §4.3；（不发布）

未决与下一步

- 10-19 22:55 已做与样本无关的准备：（自写检查清单与两组提示词，待冻结）、（合成数据冒烟测试通过）。平台已 pplan approve（A149）。
- Liang Hu 批启动方案 → 按 §2.7 里程碑开工；开工前委托 litwiki 给 Liang et al. 2024（NEJM AI）建卡核页码。

- 精读卡小修建议（交总控转 knowledge）：渲染脚本 存在，只是 SKILL.md 路径对不上。

文献依据

见启动方案 §4.2。10-21 litwiki 建卡： - Liang et al. 2024, NEJM AI, doi:10.1056/AIoa2400196，卡。其"重合率"是以模型要点为分母的定向命中率（GPT-4→单名人类：Nature 家族 30.85%、人→人 28.58%；正式版 PDF p. 4–6），由 GPT-4 抽要点、GPT-4 判匹配（相似度 ≥7），人工抽检匹配 F1 0.824（预印本 PDF p. 9）。**本快试的覆盖率以人类意见单元为分母、把同篇全部审稿人意见合并，口径不同，数字不可直接比。** - 同类先例简卡：Tyser 2024（arXiv:2408.10365）、Fichtl 2026（arXiv:2608.03581），同目录。

参数来源表

参数	取值	来源 / 假设
覆盖增量阈值	10 个百分点	Liang Hu 委托原文 / 精读卡附项
每份意见条数上限	25	假设：防止 B 组靠条数取胜；P1/P2 真实审稿意见单元数开工时核，若超过 25 再定
每组重复份数	3	假设：控制生成随机性，额度可承受
字典可标注阈值 / κ	85% / 0.6	假设：κ 0.6 为常用"较好一致"下限
起草同向率阈值	60%	假设：过半且留余量
抽样种子	20261019	本线惯例

Liang Hu 注

- 10-19 22:4x 原话：「选10篇吧，我们选在JWEIA发表的文章，选择20年内的文章，文章内容和分布尽量广泛。别的我同意，你执行吧」。→ 方案批准；样本改为 10 篇 JWEIA（20 年内、主题分布广）。
- 10-21 Liang Hu 批 L26 总报告第 7 条：无本组 JWEIA 审稿记录 → 选 b（未给 a 的目录）。
- 原卡点：JWEIA 不公开审稿意见，覆盖率没有参照。已问 Liang Hu：a 本组 JWEIA 稿件审稿记录 / b 改用 Wind Energy Science 公开审稿 / c 改参照（不建议）。

成果去向（总控 10-19 补）

- 成果（12 轴检查清单的试用结论、21 种回复动作字典的核查与打标）定稿后，用 交接给 T34.2「论文评审」Lead，不在本线另放。

引文滚雪球扩展（10-22，总控）

- 按 Liang Hu 10-22 要求用 扩展文献（OpenAlex 一层前向/后向 + 关键词），筛选记录。
- 库里没有、拟建卡的新文献已列在筛选记录里；建卡委托 litwiki 待发（10-22 00:5x 全平台委托满，已约回访重试）。卡片回来前不改本页结论或判据；可能的影响写在筛选记录末节。

与新增文献的关系（10-22 卡片回来后，总控）

- 结论与判定不改。文献里"方面/主题引导能提高覆盖"的结果用的是更宽的覆盖定义，与本试"逐条意见、同对象同方向的完全覆盖"不是同一个量：
- Yuan, Liu, Neubig 2022（JAIR）：方面辅助训练的方面覆盖 ACov 只升约 1–1.5 个点（50.37→51.50；62.64→63.96；55.37→56.91），方面召回 ARec 在摘要+CE 组反降 58.31→57.56；参照是元审稿的"方面 + 极性"，不是逐条匹配（期刊 p. 175、184–185，Table 5）。
- ReviewEval 2025：topic 覆盖 = 专家 topic 中至少有一个 AI topic 达中等相似阈值的比例，作者本身提示不能当作逐条意见命中率（PDF p. 4 / 印刷 p. 20545，式 1–2）。
- 读法：在宽定义下增益也只有约 1 个点量级，与本试"完全覆盖 Δ +0.1 pp [−2.2, +2.4]"方向一致，不构成反证。
- Thakkar et al. 2026（Nat Mach Intell，ICLR 2025 随机实验 44,831 篇审稿）回答的是"给人类审稿人 LLM 反馈后审稿是否更新"，随机指定组平均长度增量差 14 词——问题不同，只作背景（预印本 PDF p. 3–4、7–8；出版版见卡片，PDF p. 2、4、6、8 对应期刊 p. 327、329、331、333）。

10-24 补记（Lead，只用本地已有资料）

- 10-21 已按方案 b（Wind Energy Science 公开审稿，10 篇，433 条首轮审稿意见）跑完，结论"放弃引入"，头 conclusion；统计见 、response_actions_stats.md、drafting_stats.md。
- 知识库已落地：来源笔记 *.md 第 20 行补了 `Trial：不灵`；方法卡 已建（只存"意见—证据—动作—状态"表格格式）。
- 10-22 引文滚雪球补充的文献（Yuan 2022、ReviewEval 2025、Thakkar 2026）不改结论，见上节。
- 现状：无在跑计算、无在途。建议结题（待 Liang Hu）：按开工前判据已有定论。

10-26 恢复：NHESS 子样本（Liang Hu 批 A293）

- Liang Hu 10-26 原话「我们能否采用一个气象那边的期刊？我知道他们是有这种期刊的 例如这个 [external URL omitted]，经总控转达批 A293：补 10 篇 NHESS 公开讨论稿（风灾优先、20 年内、主

题分散）。

- 协议不改：判据（10-19）、提示词与检查清单、拆分规则、盲评流程（10-21 冻结）全部沿用。只换两处措辞：审稿提示的期刊名；判者 invalid 定义里"风能/流体/模拟论文"改为"风灾/自然灾害论文"。
- 选样规则 10-26 11:35 写定，在看任何候选之前：。
- 结果作为「NHESS 子样本」与原 433 条结果并列；只有方向相反时才讨论改总结论。
- 10-26 12:2x 完成：10 篇（H1–H10）、314 个真实意见单元、60 份模型审稿意见（1500 条）、20 份盲评；结果首「最新：NHESS 子样本结果」。状态改回 放弃。0 SU、0 CU。

关键结果图