NATHAZ AI LAB / 技术报告 · 探索试验

L26.12 稀疏自编码器可解释性迁移

分组 快试实验室

状态 放弃

起止 2026-10-24 23:22 — 2026-11-11 21:29

阶段结论

项目报告

L26.12 稀疏自编码器可解释性迁移

批准：Liang Hu 10-26 批 A289，pplan approve。先试 R23 Pangu。写入范围 、。

原文核对（第 0 步，10-26）

原文：Liu, Li, Sun, Ni 2026, arXiv 2610.28904v1（投 GRL），22 页。Zotero GV6PQBKB / 附件 DVIHW7UE；项目副本。下称页码均为 PDF 页（与稿件页脚编号一致）。

核对项	原文做法	出处
模型与层位	GraphCast 0.25°（ERA5 1979–2017 训练）；16 个 processor 层，每层 40,962 网格节点 × 512 维隐状态；主分析层 Layer 8	PDF p.5
SAE 配置	TopK SAE，字典 4,096，K=32；架构沿用 MacMillan & Ouellette 2025；每层 5 个种子（50108–50112），共 80 个字典	PDF p.5, p.9

核对项	原文做法	出处
SAE 训练/验证/分析的时间划分	SAE 用 1979–2017 隐状态训练（无台风标签，无监督），2018–2021 验证重建；台风分析只用 2018–2019	PDF p.5
风暴划分	**没有风暴级训练/检验划分。** 205 场风暴、2,115 个时次、4,118 个风暴—时次记录全部用于一套 2018–2019 分析；特征**挑选**（按中位 F1 选 Top-1/Top-4）与属性对应的**评估**在同一批风暴、同一批时次上做	PDF p.5, p.8–9
事后选择	Top-4 的个数"在看过参考字典全景后探索性选定"，再固定用于全部 80 个字典	PDF p.9–10
属性定义	位置：特征正激活区与 IBTrACS 中心+R34 掩膜的 F1；强度：掩膜内 ERA5 海平面气压距平最低值（不是 IBTrACS 最大风），与特征掩膜内最大激活各自 min–max 归一后的差 D；结构：±12° 内特征激活与 −p′ 的空间 Spearman ρ（风暴内空间相关，不是跨风暴的强度相关）	PDF p.5–8
主要数字	Layer-8 参考字典 f613：中位 F1 0.512、D 0.180、ρ 0.644；5 个种子的 Top-1 中位 F1 0.345–0.512	PDF p.9, p.11
有无干预/消融	**没有。** 作者明说读取只证明"对应"不证明"被使用"，是否被模型依赖需要干预或消融（指向 MacMillan & Ouellette 2025）	PDF p.13
作者自认局限	未测 SAE 字典大小、稀疏度、Top-k 子集大小的敏感性；只一个模型、两年、单步	PDF p.13
公开材料	SAE 检查点、分析代码、处理后结果：Zenodo 10.5281/zenodo.23492703；ERA5 输入取自 WeatherBench 2 公开 zarr（GCS）	PDF p.14–15

读法：原文的结论只到"相关/对应"，且挑选与评估同集（选择偏差未量化）；时次间相关未处理（每场风暴平均约 10 个时次）。这些只影响对原文的评价，不改本项判据——本项按风暴 + 年份划分并做干预（启动方案 §2）。 **对本项有用的两点**：①WeatherBench 2 的 ERA5 zarr 公开可读，启动方案 §5/§6 的"ERA5 云端副本待核"有了现成来源；②干预的先例在 MacMillan & Ouellette 2025（arXiv 2512.24440，已取到，Zotero ANNAEAZP），第 3 步干预方式参考它。

文献取件（10-26）

文献		结果
Liu et al. 2026, arXiv 2610.28904	确无	取到，Zotero GV6PQBKB
Cunningham/Huben et al. 2023/2024, arXiv 2309.08600	确无	取到，Zotero TAZDXFZX
Gao et al. 2024, arXiv 2406.04093（TopK SAE）	确无	取到，Zotero Q7T83PB8
MacMillan & Ouellette 2025, arXiv 2512.24440（GraphCast SAE + 干预）	确无	取到，Zotero ANNAEAZP（启动方案外补加：干预先例）
Bricken et al. 2023 Towards Monosemanticity	确无	只在 transformer-circuits.pub 网页发表，无 DOI、无 arXiv， 不支持；交 litwiki 判断能否按网页建卡
Templeton et al. 2024 Scaling Monosemanticity	确无	同上

试过与结果

步	时间	结果	证据
第 0 步 原文核对	10-26	无风暴划分（选/评同集）；无干预	本页「原文核对」
第 1 步 截断闸门	10-26 16:35–16:51	**通过**：pangu_weather_24.onnx（ECMWF 镜像，sha256 …）在第 3856/7717 个节点处截成两段，边界为主干（1×131040×384，粗分辨率层）+ 编码器跳连（1×521280×192）；两段串联与整网两路输出最大相对差均为 0（判据 <1e-4）。整网合理性：2019-09-01 12Z 起报 24 h，MSL RMSE 78 Pa（持续性 598）、Z500 RMSE 137 m^2/s^2（持续性 564）。附加：跳连张量整体×1.01 输出有限，MSL 最大变化 33 Pa	；首跑构图错误（常量当浮点输入）见

| 第 2–3 步 相关 + 干预 | 10-26 16:57–19:16 | 训练 275 场 / 检验 2021 年 46 场（每场 1 时次，事后缩样；WB2 实际只到 2021）； SAE 宽 1536、K=64；①主读法不满足（最好下界 0.660 < 置换最大 0.679），并列读法

①②满足但③不满足；发散 0/3900；纯解码替换 α=1 中位 0.995 hPa |；结论草案 v1 |

| 出路 B、C（L26.12-02） | 10-26 20:31–21:08 | B：同程序复现原结果；3 种子置换 1,000/自助 5,000，主读法①都不满足（991 差 −0.015 至 −0.054），置换极值种子极差 0.033–0.082；C：补 12 场（4 场无 t+24 位置）共 42 场，③判定不变，目标中位 |E| ≤0.064 hPa，发散 0/5,460 | |

| 出路 A（L26.12-03） | 11-03 10:44–12:22 | 切点 [local path omitted]（7651/7717），闸门过；SAE 宽 1536、K=64；气压/286 检验 |ρ| 0.831 过主读法①但不过②（PCA 0.886）；风/286 等并列读法过①②；③全部不过（干预最低气压变化全为 0，结构性）；(i) 20 种子差 [−0.051,+0.042] 跨 0 | |

资源台账

时间	项	CU
10-26	第 0 步（无计算）	0
10-26 16:35–16:51	第 1 步闸门，A100 会话 l2612-gate 约 16.3 min（含首跑失败一次），已 stop	≈1.5（按 5.4 CU/h 折算）
10-26 16:57–19:16	第 2–3 步，会话 l2612-sae-step2 约 2.31 h，已 stop	≈12.5（5.4 CU/h 折算）
10-26 20:31–21:08	出路 B、C，会话 l2612-bc-step3，≤0.62 h，已 stop	≤3.34（保活未执行最终拉回：keepalive 记 stopped、final_pulled 空；结果以本地 step3 文件为准——interventions_remaining.jsonl 1572 行、进度末行 done/12 场、b_results.json 可读，10-26 Lead 核）
11-03 10:44–12:22	出路 A，会话 l2612-postmerge-stepA 1.64 h，已 stop	≈8.9
11-10 00:05–(回收时刻不明，≤01:29)	出路 H，会话 l2612-stepH，00:19 平台停机后被回收	≈1.4–7.6
11-10 23:29–11-11 00:33	出路 H′，会话 l2612-stepH2 1.07 h，已 stop（40/42 场）	≈5.8
	累计	**≈33.4–39.6 / 停止线 39 / 上限 40**

参数来源表

参数	取值
Pangu 权重	pangu_weather_24.onnx，1,181,711,187 B，sha256 613a5c140a1399abcaffb4dbce32af373a1f5f56c515704f5be61925bb9fdcfd
ERA5 输入	WeatherBench 2 0.25° 6 h zarr，纬度翻成 90→−90
SAE 字典倍数、K	启动方案写 4–8 倍、TopK；原文 4096/512=8 倍、K=32

文献依据（10-26 litwiki 建卡）

- 原文： GraphCast，特征在 2018–2019 同一批风暴上挑选并评价，无留出、无干预（与本页「原文核对」一致）。
- 干预先例 （PDF pp. 7–9）： GraphCast 第 8 层，只把 f3243 系数乘 1+γ、加回重建残差——与本项 L26.12-01 的 h' = h + (α−1)·z_k·d_k 同一做法（α=1+γ）。其 γ=+0.5 在 10 天 40 步、每步重施的自回归预报里出现失控、非物理响应。本项是单步 24 h、只施一次，但 α=2（γ=+1）大于其最大幅度，发散按判据计入"不判"条件，需逐 α 报。
- 方法：、（TopK 定义与 K、宽度选取）； 网页版 、。

停止类别

11-11：否定结果（限本配置；干预 40/42 场，部分）——六审 裁决 （A 主张保留卡住，未采纳理由见裁决）。以下为历次记录： 11-03：出路 A 后仍为**卡住待 PI**（否定条件 (i) 不满足；汇合后层干预无分辨力），卡住报告与 Lead 建议见。以下为 10-26 记录： **卡住待 PI**（10-26 21:45，六审 裁决）。判据词按写定判据为「放弃（限本配置）」，但分辨力（①在抽样噪声内、③无效应界限）与失败原因（跳连未干预）两条不满足，不登记为否定结果。卡住报告、出路代价与 Lead 建议见 §5 与「Lead 建议」。

11-03 A304 批复

Liang Hu「都按建议批准」→ 出路 A：跳连汇合后的层重测，上限 33 CU、30 CU 即停，0 SU，不扩展到 D、E。决策；已派子项目。

出路 A（11-03）

Liang Hu 11-03 按 A304 Lead 建议批准；任务书 （否定条件 (i)(ii) 的操作定义 11-03 开跑前补定）； 11-03 10:44 起会话 l2612-postmerge-stepA：闸门通过（切点，1×521280×384，段 B 只有这一个非常量输入，串

联误差 0）；11:10 起 Lead 接力 SAE/相关/干预（见决策同文件 11:10 节），12:45 干预截止、12:49 回访停会话。结果写。 - 11-03 12:22：出路 A 做完（会话 l2612-postmerge-stepA 约 8.9 CU，累计约 26.2 CU，已 stop）：汇合后层①气压主读法过、风并列读法过；②风过、气压不过；③42 场全 0，属结构性无分辨力；否定条件 (i) 区间 [−0.051,+0.042] 跨 0。仍卡住（待 PI），不送六审。Lead 建议 H（约 4–6 CU，需停止线 30→32）。结论 v4。

出路 H（11-10）

Liang Hu 11-10「按你建议的推进吧」。**00:19 工作站 用户服务整体停机，保活被停，VM 回收，H 中断**（决策，结论 v5）。决策；脚本与结果；01:05 干预自停、01:09 回访停会话。

出路 H′ 重跑（11-10 23:29）

Liang Hu 11-10「好，按建议来，以后这么小的CRC计算无需批复」。决策；结果写；00:26 干预自停、00:32 兜底停会话。

收尾（11-11）

- 运行根清理：本项全部计算在 Colab，会话均已 stop/回收；**没有 CRC/TACC 运行根**，无需清理。CRC 上 L26.4 数据早已删除，与本项无关。本地 共约 67 MB（窗口归档、特征、结果表），保留。
- 再试条件见结论 v7 §5。

关键结果图