NATHAZ AI LAB / TECHNICAL REPORT · EXPLORATORY TRIAL

L22.2a Full-text search of the literature library + wind-engineering data extraction

Group First Lab (proving ground)

Status Promoted

Period 2026-10-13 18:16 — 2026-10-17 17:33

Stage conclusion

10-14 Promoted to the platform tool pages: all five acceptance groups passed, and Phase 2 non-first-page fact questions reached the target page on 22/27; Phase 3 blind test on 10-14: 21/30 reached the page (Chinese 9/10, Chinese-to-English 8/10, books 4/7, scanned books 0/3); books were weak, and after platform improvement 0062, round3 book page hits rose from 4/10 to 7/10 (meeting the target) while round4 remained 8/12; the desktop I drive is connected and inventoried: net new ~12.5k PDFs / 420k pages, with Phase 1 extracting 289k text-layer pages (1.8 GB on the workstation); desktop corpus 0069 went live (10-16), hitting the target page on 11/30 in the 台式机 blind test (vs. 24/30 for the two libraries), with improvement leads handed to the platform; 10-15 all tracks pushed forward: OCR of the remaining 105k pages completed at 10-16 02:38 (105,336 pages, handed to 0069), three-library metadata and work-level deduplication, 31,365 pages of djvu/pdg books handed to the platform (472 Chaoxing-format pages unresolved), and litwiki/knowledge trial results returned; ingestion awaits 0051 and C drive cleanup. 10-13 conclusion: retrieval only. Two libraries with 4,691 PDFs / 129k pages indexed locally by page; for non-first-page fact questions, top-5 results hit the exact page about half the time (English 8/14, Chinese originals 5/5, Chinese queries on English papers 3/5 after query translation, books 4/6), paper-level 1/27; platform integration underway (three phases, Phase 1 within the week), prototype frozen as baseline; `pages` Phase 1 is live (tested 10-13 22:40); OCR of 79 scanned documents / 5,422 pages handed to Phase 2. Profile extraction is Shelved (single-

page text had 6/78 errors and 27/78 requiring qualification, with figure pages often mislocated); 0 CU; books on the other computer await information from Liang Hu

Project report

文献库全文检索 + 风工程数据抽取

目标

回答"Liang Hu 的论文库/书籍库怎么用最值"。不微调大模型；试 (1) 全库全文检索、可引页码；(2) 从论文中抽一类风工程数据成表。任务书。

当前状态

10-13 Liang Hu 批准开立（由 Strata 节点讨论引出）。10-13 18:20 最小试验已派 ideas（任务书副本）：A 全库按页建 BM25+小向量混合索引，≥30 题事先定判据（前 5 条命中正确论文+页 ±1），与 对比；B 30–40 篇下击暴流竖向廓线（z_max、U_max、廓线模型参数、r/D、页码图号）走 抽取，≥60 值核原页算准确率与核对工时。下击暴流选文参考风场线清单（windfield_step2，约 120 篇，只读）。已知：Zotero 3,163 PDF / 17.7 GB，2,422 个已有全文文本缓存；现有 只覆盖已建卡文献，未见全库全文索引。书籍：10-13 Lead 在 工作站 上找到两处——Zotero 内 87 本书 + 32 章节 + 60 篇学位论文；EndNote 博士文献库 （1,527 PDF / 6.7 GB，含 Kaimal & Finnigan、Naudascher 等书及中文文献），已纳入范围（补充，排在 之后进同一执行）；可能还有书在别处，待 Liang Hu 告知。

语料清单（10-13 ideas 盘点， +）

PDF 附件	库内去重后候选	大小	有文本层 / 整件无文本 / 抽取失败	语言（前 5 页启发式：英/中/混/未知）	类型
3,164	2,592	16.5 GiB	3,061 / 83 / 20	2,959 / 2 / 95 / 108	书 73、书章 26、学位论文 50、期刊 2,870、其他 145（按附件；条目口径为 87/32/60）

PDF 附件	库内去重后候选	大小	有文本层 / 整件无文本 / 抽取失败	语言（前 5 页启发式：英/中/混/未知）	类型
1,527	1,348	6.2 GiB	1,440 / 76 / 11	1,402 / 0 / 35 / 90	1,517 未分类（.enl 元数据未解码；≥150 页长文档 56 个）
4,691	约 3,845 候选作品簇（跨库同名簇 95，非精确）	22.8 GiB	已索引 128,708 页；整件无文本 159 件 / 10,553 页（不等于扫描件数）	有文本层的中文文献极少：中文书多半是扫描件，待 OCR 抽样	—
Literature 12,933 + Book 1,060 可读 PDF（另 132 件打不开）；字节去重后与两库仅重 53 件 → 净新增约 12,497 件 / 42.1 万页（现有两库的约 3 倍多）；.djvu 62 本约 3.0 万页；超星 .pdg 11 本约 3,163 页	去重净 15.9 GiB	抽样估约 12.7 万页无文字层需 OCR（Book 中文名约 90% 是扫描件），工作站 10 线程估 80+ 小时	抽样中 124/英文或混合 406/未知 138（668 份）	字节去重低估重复（同作品不同版本认不出）；PhDBackup 与 EndNote 博士库字节不同	

已定决定

- 不做微调，检索优先（审查 裁决第 4 条）。
- 不需要本地大模型：检索用小向量模型/关键词，抽取走 Gemini 批量通道。

试过与结果

日期	做了什么	结果一句
10-13	补充（ideas）：EndNote 库 + 库内书籍增量入索引，中文 CJK 三元索引 + 小术语表；新增 6 道书籍内页题	英文首页题扩库后不变（混合 27/34）。书籍 6 题只中 1 页：英文书题 1/3（B02 中，B05/B06 未中），中文问英文书 0/2，中文问中文书 B04 只中书未中页；原 34 道中文问英文论文 0–2/34。Lead 复核：失败主要是**跨语言**和**只靠关键词召回**（向量模型只在关键词前 60 页里重排、且只懂英文），以及两库同一本书重复占前 5

日期	做了什么	结果一句
10-13	第二轮（ideas）：30 道非首页事实题（3 道题本身有误作废，有效 27），前 5 按标题+页去重；抽取 AI 逐页复核 78 值；8 篇校正图页送 Gemini 看图读数	检索（前 5 论文+页）：英文事实 8/14（找到论文 10–11/14）；中文原文 5/5（三元索引）；中文问英文 0/5，只译问题后 3/5；书籍 4/6（实体书 2–3/4）；论文级 1/27。抽取：78 值中 45 同页文字支持、27 需限定工况/定义、6 错；8 篇中 5 篇目标图其实在别的页；图读 AI 与 Gemini 5 篇粗略一致，误差无人工真值未评估。Lead 抽核 5 道题标准答案（R01/R07/R13/R21/R27）均在原页
10-13	扫描件 OCR（ideas）：159 件无文字层 PDF 本机 Tesseract，去重后 79 份 / 5,422 页，22:00–22:35 完成，0 CU	5,407 页有文本；20 页文本抽查 8 页有专名/数字错、8 页公式失真；Lead 对照 Wilcox PDF 第 40 页原图：正文基本正确、公式乱。可做关键词召回，不能直接引公式/数值。已交平台 0034 二期入库
10-14	平台验收（0034 一期 10-13 22:03 / 0038 二期 10-14 01:58，逐题文件）	一期五组全过线：首页 29/34、英文事实 6/11（有效题口径，原型 5/11）、中文原文 5/5、书籍 5/6、中文问英文 3/5；二期 round2 有效 27 题 22/27（目标 20）、英文事实 9/11、34 道中文问英文首页题 31/34 到页、跨库重复已合并。弱项：第一轮 6 道书籍补题两期都只 2/6 到页。Lead 已核 SHA 前缀与 R13–R16 逐题
10-14	三期盲测（ideas，30 题冻结 SHA，题目不给平台），pages 一次调用/题	到页 21/30、作品 25/30：中文原文 9/10、中文问英文 8/10、有文字层的书 4/7、扫描书 0/3（作品 2/3）。书籍内页普遍偏弱（与一二期书籍补题 2/6 一致）；发现元数据错挂：《热带气旋动力学引论》OCR 结果显示为 1949 年论文标题（Lead 已在原始输出核实）。聚合结果已交平台三期单列改进
10-14	台式机第一阶段（ideas）：12,497 个净新增 PDF 在台式机远端抽文本，经 SSH 传回 工作站，PDF 不落盘	成功 12,489 件 / 418,747 页，其中有文字 288,794 页、无文字 129,953 页（第二阶段 OCR），8 件分页异常（2,276 页）待诊断；工作站 实占 1.8 GB（小文件块开销），C 盘 52 GB。Lead 抽 2 页回原 PDF 重抽，内容一致
10-15	台式机第二阶段收尾（ideas）：OCR 停在 24,615 页（全是 Book/中文；10-14 20:46 因 C 盘<40 GB 自停）；导出打包清单；补 2 件异常 PDF	SQLite 418,861 页记录 / 12,491 件可入库（文字层 394,132 + OCR 24,615）；剩 105,338 页未 OCR（Book 其他目录约 2.7 万、Literature 约 6.9 万）、6 件损坏 PDF 2,162 页；20 页抽查：公式/数值/专名常错。已交平台入库

日期	做了什么	结果一句
10-15	平台 0062 上线后复跑两套盲测（ideas，pages）	round3：到页 21→24/30，书籍 4/10→7/10（达三期目标），中文持平；round4（12 道书题）8/12 不变。剩余失败主要是整本书没被召回，书一召回基本就到页；聚合结果已交平台
10-15	knowledge bot 试用 pages 复查 10 张知识卡出处	2 张命中原文页、2 张命中相关文献、6 张未检到。Lead 核 Zotero：未检到的 6 篇中 5 篇不在库里、1 篇有条目无 PDF（YY6ZFJJC）→检索本身没失手，缺口是"用户分不清没检到与库里没有"，已建议平台加提示。bot 反馈：准确英文题名 + 具体数值/方法提问最好用；宽泛中文主题或只给 DOI 会被相近文献占位
10-15	LitWiki 试用 pages 复查 10 条已核页码的引文	首问 5/10 命中目标页，换问法后 7/10；失败都是"论文已知、要在其中找某页"时被同系列别篇或参考文献页占位。LitWiki 建议接入建卡流程作候选页定位，核引文仍须开原 PDF；已向平台建议加 限定作品内检索、精确题名加权、推算期刊页醒目标注
10-15	书目元数据第一轮（ideas，metadata/）：EndNote .enl 解出 1,373 条、安全关联附件 1,122/1,527；台式机 12,491 件题名全部低置信（7,092 来自文件名、5,399 来自首页启发式，socket 过期未读 PDF Info）；三库候选作品簇 15,009	30 条抽查可用率 23/30：EndNote 9/10、台式机 5/10、跨库簇 9/10。只能作候选关联，不能当正式书目；台式机与两库同 DOI/同指纹的只有 34 件（去重仍是保守下界）。第二轮：A Crossref 核 912 个 DOI 候选回填题名（已派）；B 等重抽单导出 pdf_meta.jsonl 后补 PDF Info 题名/作者再聚类
10-15	.djvu/.pdg 转文本（ideas，台式机 工作目录，14:25 完成）	无 sudo 改 `apt download` 解包 tesseract 4 + djvulibre 到用户目录（可行，其他单复用）。交付 djvu_pdg.sqlite：73 个文档 / 31,365 页（DjVu 61 本 28,391 页 + Melenk 恢复 282/283；超星 PDG 11 套 2,692/3,163 页），有文本 31,140（文字层 24,637 + OCR 6,728）；472 个失败页位（PDG 0x38 变换 398、附加图层 72，集中在《风工程导论》《钢桥》）等更完整解码器；10 页抽查文本正常。Lead 核 工作站 文件 sha256 与页数一致；已交平台 0069 追加
10-15	台式机 OCR 第三阶段（ideas，工作目录，10:29 起后台 PID 63579，6 线程）	复用 pkg 里解包的 Tesseract；200 页试跑 36 秒（约 5.5 页/秒，195 页有文本）→ 105,338 页外推约 5.3 小时，预计 10-15 下午至晚间完成；损坏 PDF 用 pypdf 修副本另行处理中。完成后 ocr_round2.sqlite 回工作站、导 manifest，再交 0069

日期	做了什么	结果一句
10-15	台式机文本重抽（ideas，工作目录，10:47 起 6 进程，PyMuPDF blocks 按左右栏排序）	目标 12,437 件 / 394,246 页，OCR 页原样带入；10:49 约 22 页/秒；**13:2x 已完成**（12,436 件 ok、1 件 error，394,243 文字层页 + 24,615 OCR 页），收尾交付与书目 B 已派；OCR 单因并行放慢到约 3 页/秒 → 约 10 小时（预计今晚）。台式机负载约 14（24 核），仍有余量。完成后交 50 页双栏对照、manifest、回 工作站
10-15	书目第二轮 A（ideas，Crossref 只送 DOI 字符串）：1,942 个独立 DOI 候选（台式机 912、EndNote 1,070）	1,178 条来源记录与 Crossref 题名一致（≥0.82 相似度）→ 回填高置信题名/第一作者/年份到 *_v2.csv；258 条疑似误抓（DOI 能解析但题名不符）；22 条不存在；522 条 DOI 含 OCR 乱字（如"共/天"）判"未核实"（勘误：首版误记为不存在）。与 Zotero 同 DOI 的来源记录 1,065 条*（字节去重只认出 34 件）→ 跨库真实重复远多于此前估计，作品级合并要靠 DOI/题名。7 条题名一致但年份差>1 年待人工看
10-15	重抽收尾 + 书目第二轮 B（ideas）	v2 已回 工作站（895 MB，418,858 页，sha256 两端一致；1 件 PDF 只开得出 2 页列异常）；50 页双栏抽样中 17 页能确认左栏句子连续、其余需人工看。书目：台式机 12,491 件题名置信五级 138/1,256/989/8,540/1,568；522 个乱字 DOI 一个都没能安全修复；候选作品簇 15,159：只台式机 12,272、只 Zotero 1,538、EndNote+Zotero 1,065（EndNote 约 70% 与 Zotero 重合）、只 EndNote 278、台式机与 Zotero 重合仅 6 簇（Lead 复算，CSV 含 NUL 已让清）；30 条抽查 24/30（Crossref 10/10、PDF Info 6/10、EndNote 8/10）。已连同 v2 交平台 0069
10-16	台式机 OCR 第三阶段完成（ideas；10-15 23:3x 台式机 WSL 根分区 emergency 只读中断，Liang Hu 重启后 10-16 00:49 续跑，02:38 交付）	105,336/105,338 页（有文本 103,456、空 1,880），2 页渲染超时、6 件损坏 PDF 未入；ocr_round2.sqlite 256 MB 两端 sha256 一致、integrity ok（Lead 复核）；20 页抽查可辨但中文字形/公式/表格错误常见。已交平台 0069 追加。**台式机语料至此交齐 ≈55.6 万页**

日期	做了什么	结果一句
10-16	0069 上线后验收（ideas）：round5 台式机盲测首跑 + round3/4 复跑	round3 到页 24/30、round4 8/12，与 0062 持平无变差（长书召回改进暂无可见增益）。round5 首跑 5/30，但 30/30 撞上翻译通道故障（全回退中文检索），英文来源两组 0/10 不能裁决，作废重跑（Lead 20:58 实测翻译已恢复）。显示检查：台式机来源与 I:\ 路径 8/8 正确、扫描页提示 3/3；题名 4/8 为'题目候选'、3/8 为 PDF Info 十六进制乱码（已报平台过滤）
10-16	round5 重跑（翻译恢复，30/30 翻译成功）	**台式机来源到页 11/30、作品 15/30**（Book 4/10、论文 4/10、中文 1/5、OCR 2/5），明显弱于两库（round3 24/30）。主因作品没召回（15/30）；中文组翻译成功后反降（首跑只用中文原文时作品 5/5）→中文问句应中英两路都检；题名 12/15 仍是'题目候选'。三条线索已交平台

未决与下一步

- **10-16 21:40**：round5 正式成绩到页 11/30（平台说明：测的是 09:42 版，尚不含 ocr_round2、djvu_pdg 两个增量，向量还在建）。四条改进（中英两路检索、台式机与两库分别召回再合并+题名加权、副本各用自己的物理页、用 desktop_records_v3 题名替换文件名）写进 0069 第三轮；回归要求两库逐题不降、耗时增加 ≤5 秒。上线后平台通知，实验室用同一套题复测，在此之前台式机来源验收不下结论。
- **10-16 20:46**： pages 已返回台式机来源（0069 上线，平台尚未正式通知）；已派 ideas 跑 round5 + round3/4 复跑。
- **10-16 02:45 状态**：台式机三个来源（v2、djvu_pdg、ocr_round2）全部交平台 0069；等入库上线→round5 盲测 30 题 + round3/round4 纵向对照。剩余未解：PDG 472 页（解码器）、6 件损坏 PDF、2 页超时。
- **10-15 09:05 Liang Hu："I 盘其他目录暂不管，别的全部推进"。**已派（写入范围互不重叠）：① ideas 台式机 WSL 就地 OCR 剩余 105,338 页（台式机 24 核/46 GB/盘 664 GB 空闲；无 sudo，改 micromamba+conda-forge 免 root 装 tesseract 等；首派因 socket 过期未开始，09:20 重建 socket（3 天）后重派；输出 工作目录→工作站 ocr_round2.sqlite）；② 书目元数据第一轮已交（候选级）；第二轮 A 已交（1,178 条高置信回填；与 Zotero 同 DOI 1,065 条）；B 已交（见试过与结果）；v2 + 书目表 10-15 14:05 交平台，**0069 14:1x 放行入库**（新约束：新增 ≤8 GB、C 盘 <85 GB 停；虚拟盘内部尚有 117 GB 空闲）；旧 page_text.sqlite 与旧 manifest 已删（14:20）；ocr_round2、djvu_pdg 交来后同工单追加；round5 台式机来源盲测 30 题已冻结（SHA；Book 10 / 论文 10 / 中文 5 / OCR 5），OCR 5 题 Lead 已目视原页核实，等 0069 上线跑分；③ .djvu/.pdg 单 14:25 已交付并交平台 0069；OCR 第三阶段 10:29 起在台式机全量运行，**23:3x 做到 102,850/105,338 页时台式机 WSL 根分区进入 emergency 只读（ext4 报错自动 remount-ro），进程退出**；已把 SQLite 备份到 工作站 ftkb_desktop/ocr_round2_partial/（102,850 页，integrity ok）；Liang Hu 重启后 10-16 00:49 续跑、02:38 完成并交付（见试过与结果）；工作站 上的临时备

份 ocr_round2_partial 已删；重抽单 10:47 起也在台式机跑（约 5 小时）；ideas 自约回访 13:20、14:29；兜底回访 10-16 08:2x；④ 平台 0069 答复（10-15）：线上两库已按文本块排序无串行；台式机 page_text.sqlite 是 -layout 抽的须重抽，0069 只收重抽版→已派 ideas 在台式机用 PyMuPDF blocks 重抽交 page_text_v2.sqlite（加 extractor 列）；0069 预留 work_id 合并与标题/作者/年份显示、多来源 SQLite 增量追加（主键 sha256+物理页，后到来源只补空页/替换 OCR 页）。开工条件：C 盘 ≥100 GB + 重抽版交付；⑤ litwiki、knowledge 试用已回（见试过与结果 10-15 两行）：检索本身未失手，两处改进建议（库内无/无 PDF 提示；--key/--doi 作品内检索）已交平台排 0069 后；⑥ 已问平台增量索引与调用量。暂不动：I 盘其他目录；下击暴流抽取仍搁置。

- 10-14 14:20 第二阶段已派 ideas：本机 OCR 129,953 页（先 Book 中文/风工程/规范等），实测 6 线程约 1 页/秒（中文识别慢），全量约 1.5 天；10-14 20:46 因 C 盘低于 40 GB 按规矩自动停下，已识别 24,615 页（24,360 页有文字），剩约 10.5 万页；C 盘 22:24 剩 24 GB（增长来自 .hermes、[local path omitted] 等，非实验室），已紧急报平台，C 盘恢复到 40 GB 以上前不重启；10-15 00:53 复核：A3 进程已全部不在、目录稳定 11 GB、C 盘回升到 21 GB。**按 10-14 Liang Hu 新规（工作站 不跑计算、不存计算数据），剩余约 10.5 万页 OCR 重启前要另定地点**（工作站 本机需报平台；书籍不能上 Colab；CRC 组空间约 95% 满），C 盘恢复后再定（10-15 02:32 C 盘 46 GB）；建议方案：在台式机 WSL 上就地 OCR（数据在那，不用传输、不占 工作站），需 Liang Hu 同意在台式机装 Tesseract；10-15 02:45 第二阶段阶段性成果（41.9 万页）已交平台，入库（等虚拟盘压缩、C 盘回到 100 GB 以上再派）；平台 0062 书籍改进 10-15 02:09 上线，复跑结果平台已接受（三期目标达到）；长书作品级召回改进并入 0069（书按章节/页组二级索引、术语向书籍加权、平台自建 ≥20 道整本未召回题），0069 等 C 盘回到 100 GB 以上开工，上线后实验室用 、 做纵向对照；剩余 10.5 万页 OCR 等 Liang Hu 是否同意在台式机装 Tesseract；第一阶段 41.9 万页已打包进 1,003 页逐字核对无误）；8 件异常中 2 件可补页码，FE-Handbook 等损坏；.djvu/.pdg 在 工作站 不装软件转不了，暂缓；工作站 新增合计 ≤4 GB；顺带诊断 8 件异常 PDF、评估 .djvu/.pdg。完成后 manifest 交平台，平台等 0051 与 C 盘处理后入库。
- **10-14 已转正**：检索做成平台工具 pages（一期、0038 二期），所有 Lead/bot 可用。英文事实口径定为有效 11 题（我原写的 ≥8/14 是把原始 14 题原型值误标为有效题口径）。
- 三期盲测已交平台（10-14 10:15）：中文可用，书籍内页偏弱、OCR 书错挂书名，平台开 单列改进（长书书内找页+OCR 噪声补偿、错挂书名修正、跨库同作判定、中文翻译双路兜底）；上线后平台先用一二期题库回归，再通知实验室用同一套盲测题复跑交逐题结果；目标书籍到页明显高于 4/10，中文原文 ≥9/10、中文问英文 ≥8/10。原计划：实验室持有盲测题（ideas 出题跑分，10-15 前交平台 Lead），题目不给平台，并入平台约 10-20 的三期验收；重点看书籍内页是否普遍偏弱，若是平台三期单列改进。平台 10-14 已在 0034 登记一期转正。之后 原型可解冻。
- **结论（10-13 20:55）：只做检索。** 检索部分 status 待转正：形态是平台工具，不是科研项目，方案 已交平台 Lead，由平台排期；实验室提供原型与回归题库。
- **数据抽取部分搁置**：为什么不行——廓线大多在图上、每个值都要配对图号/径向位置/工况，单页文本抽取 6/78 错、27/78 要加限定，5/8 篇连图页都定位错；目前需要专家逐篇读图，自动化省不了多少工。缺什么：可靠的读图（带曲线归属）与人工真值。何时重启：有明确用途的数据集需求（例如某条线要下击暴流廓线对照库）且能接受"AI 初抽 + 专家逐篇核对"的工时；或多模态读图模型在 ≥10 篇人工真值上误差可接受。
- OCR 已完成并交平台 0034 二期（见上表）。10-13 22:40 实测 0034 一期已上线 pages：中译英生效，但跨库同书重复占前 5——平台确认一期去重未生效（EndNote 标题是截断文件名），二期解析 EndNote 元数据 + DOI/文件哈希/首页指纹去重，OCR 页入库并标"OCR 文本，引用前核原页"；QuikSCAT 查询列为回归用例。等平台交一期验收逐题结果与二期验收结果。

- 10-14 已连通台式机 WSL（内部连接，用户 [用户]，用 IP 连；known_hosts 里主机名那条是过期记录，现主机密钥与 Tailscale 登记一致），清点完成（见语料表）；10-14 第一阶段已派 ideas：有文字层页按页抽文本到 PDF，工作站 新增 ≤4 GB；OCR/.pdg/.djvu 放第二阶段。**存储更正**：WSL 盘是 C 盘上的 vhdx（355 GB），WSL 显示的空闲是假的，真实上限是 C 盘剩余（10-14 47 GB）；已报平台。平台回复（10-14）：台式机文本入库排在 0051 之后，且等 C 盘问题解决（42 万页索引预计 4–6 GB）；结果标"来源：台式机"、显示 I:\ 原路径；实验室交 manifest 后平台开入库工单。C 盘回收需压缩虚拟盘、全平台停 10–30 分钟，已列入平台待 Liang Hu 决定清单第 11 项。此前：工作站 无 I 盘；台式机（Windows，Tailscale 在线）SSH 拒绝 工作站 密钥、SMB 未共享；台式机 报主机密钥变更，已停未绕过。已请 Liang Hu 加 工作站 公钥或开只读共享；能访问后先只做清点，不拷贝。
- 等 Liang Hu 告知另一台电脑上书和论文的位置、数量、是否扫描件；>5 GB 的拷贝目的地由 Liang Hu 定（倾向 WSL 本地盘）。
- 10-13 平台 Lead 决定接入：，分三期，一期本周内。实验室承诺： 与 脚本、题库在一期验收前不动（已告知 ideas）；回归题库与分数线已回平台（底线不低于原型：首页 ≥29/34；round2 分组 英文 ≥8/14、中文 5/5、书 ≥4/6、中译英 ≥3/5；目标 round2 合计 ≥20/27）。平台已把五份题库与分数线写进 0034（10-13）。等 0034 一期验收结果，验收通过后本页改 已转正 并链接 0034；兜底回访约 10-16 晚。

文献依据

- 审查裁决 （Ovadia：无监督微调不如检索；Balaguer：有监督微调 +6 pp）。

Liang Hu 注

- 10-13："这个不需要本地大模型，对吧" —— 对。
- 10-16 02:4x OCR 第三阶段（台式机 12,491 件中的扫描页）完成： 105,336 页、1,713 件、2 条渲染超时页排除（FORTRAN90 手册），integrity ok，sha256 …；过程中台式机根盘只读故障、本地盘（9p）上的 SQLite 副本损坏（教训：Windows 盘不跑 SQLite 写入），见。交平台 0069 入库。
- **10-17 12:00**：Liang Hu 要求请审稿人诊断并提办法。Lead 先核了一遍：round5 的 30 道题目标页 30/30 都已入索引，失败都是召回和排序问题，不是覆盖问题。还查到 djvu_pdg 和 ocr_round2 两个增量仍未入索引，已告知平台。已发起审查 （3 位：Gemini、GPT-6、GLM），证据包在 （不含题目原文）。裁决后整理成改进清单交给平台，作为 0069 第三轮的参考。
- **10-17 17:35**：审查 已裁决。头号根因是 desktop_merge 门控：每题最多 1 条台式机结果，且须比两库第 1 名高 2 分。其次是台式机召回池 30、台式机书不进书通道、按页去重、低置信度用文件名当题名。已委托平台在开发集上扫参后并入 0069 第三轮，原四条里"中英两路"和"分库召回"已存在，不重做。两个增量已于 17:13 入索引，台式机现 44.4 万页。决策：。
- **10-17 17:45**：平台接手，并入，扫参尚未开始，完成后一次交四项。已约 24 小时后回访兜底。

Key figures

than the ABL–downburst case. However, at $\alpha = 180^\circ$ the temporal shift is smaller because the ABL and downburst flow align and the downburst front propagates more rapidly. The full-scale data remain in good agreement with both laboratory measurements and CFD results.

A comparison in terms of turbulence energy spectra between experimental laboratory data and LES data is presented in Fig. 9 for $\alpha = 0^\circ$ at $R/D = 1.0$ and $\alpha = 180^\circ$ at $R/D = 1.4$, respectively. The spectra are computed from the rapidly-varying reduced turbulent fluctuations ($\widetilde{u}$), which are derived based on the wind velocity decomposition technique for non-stationary phenomena (Chen and Letchford, 2004; Solari et al., 2015). Hereby, the moving mean time window $\Delta T = 0.1$ s is firstly used to evaluate the slowly varying

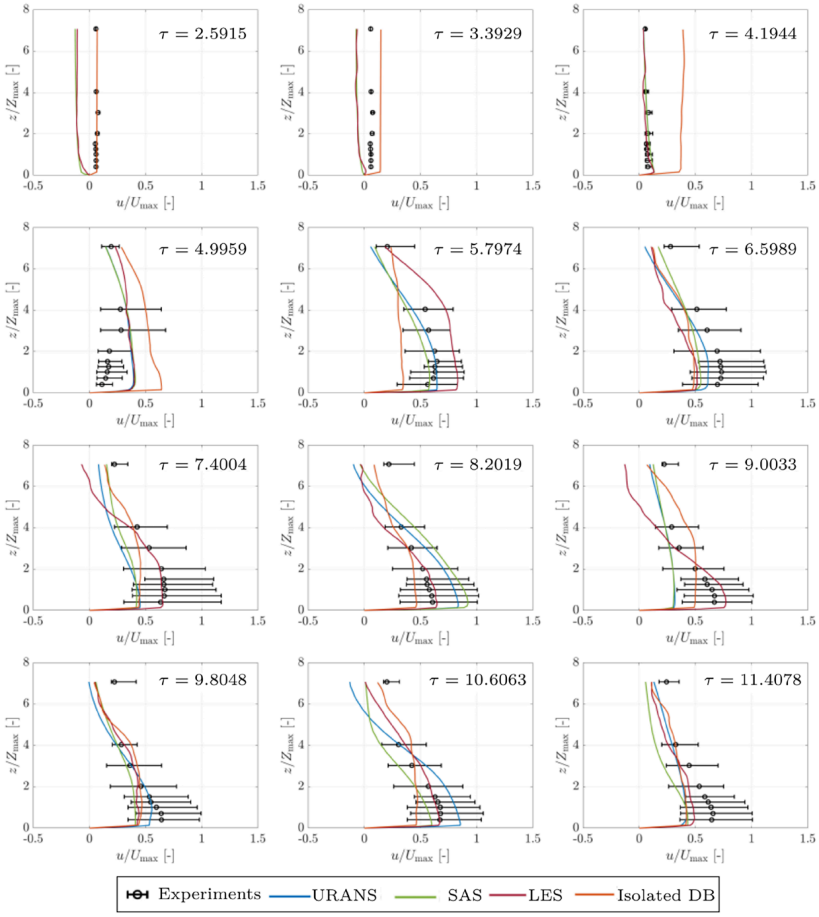


Fig. 11. Comparison of experimental and simulated vertical profiles of radial velocity (u) for α = 0° at R/*D* = 1.0, at a selected set of non-dimensional time steps (τ) (see also Fig. 2). The result of the isolated downburst (DB) wind simulated by Žužul et al. (2024) is also shown for comparison.

NXSSET4J actual figure p12

3. Flow field

Mason, *et al.* (2005) reported details of the simulated downburst wind field produced using the pulsed jet simulator. However, to aid in the understanding of the loading results presented in this paper, a brief discussion of the flow field is described.

The physical structure of the wind field impacting the model cube is made up of two parts. The first part being the initial non-stationary flow due to the pulsing of the jet, or in atmospheric terms, the gust front, and the second is the stationary field due to the steady impinging jet. The non-stationary component is made up of a succession of vortices with intermediate turbulent flow between them. The model cube first experiences what is termed the primary vortex, which is produced due to the flow instability occurring at aperture opening. Passage of this vortex is followed by an intermediate flow region that precedes the passage of a larger trailing vortex. The latter vortex was seen to be due to a combination of aperture effects and the natural shedding frequency of the jet. The trailing vortex is produced primarily as a side effect of the experimental setup (i.e., shedding); it is not known to what extent this trailing vortex would exist in a true downburst event. After the non-stationary component of flow, the cube experiences a succession of smaller vortices fed by the shear layer shed from the jet outlet. This flow characteristic has previously been documented in steady impinging wall jet flow (see for example Popiel 1991, Zaman and Husain 1980). In this paper however, it is the non-stationary region of the flow that is of interest.

The most important characteristics of the wind field for this particular experiment are the vertical (z) profiles of the surface parallel velocity, Fig. 3. For each elevation the peak velocity corresponding to the passage of the primary vortex was averaged over the five individual test runs to provide the profile shown. Mean velocities associated with the steady flow region are also shown. Velocities are shown normalised against the mean jet centre line velocity, V_j, while elevations are normalised against the jet diameter, D. The peak values represent something of an envelope of velocities associated with the vortex, and do not represent instantaneous structure. Steady flow profiles are shown as an

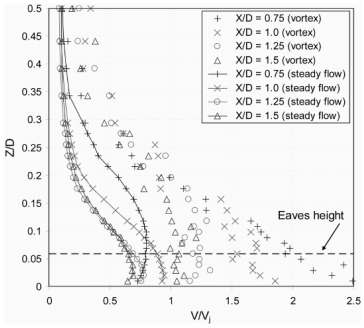


Fig. 3 Steady flow mean, and ensemble-averaged peak velocity (within the vortex) profiles at selected radial locations

GBK98YNH actual figure p5

(accuracy ±1mm representing a percentage error of ±0.04%). Vertical distance measurements were undertaken with steel rulers to which Vernier gauges were fitted, enabling measurements of the order of ±0.1mm to be made. The majority of the data presented below were measured at vertical distances of approximately 20mm above the ground, resulting in a percentage error of the order of 0.5%.

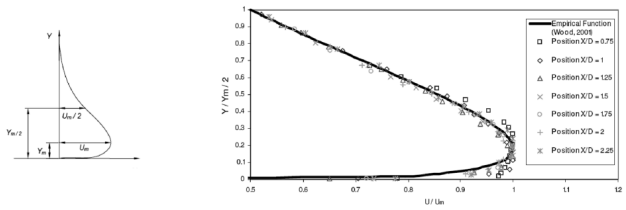
3.4. Ensemble averaging

It was observed early in the experimental programme that, whilst the measured velocities were well defined when a mean flow was established, there was significant run-to-run variation of the experimental results for the developing flow field around the gust front, resulting from the large turbulence scales generated in the flow field. Thus, unless indicated otherwise, results presented below that describe the transient effects are presented as "ensemble averages", where 10 time histories for any particular measurement case are aligned and the results averaged at each time to give an ensemble mean and an ensemble standard deviation. In order to enable comparison between the different datasets, the time is assumed to be zero when the velocity corresponds to 40% of the peak velocity, although this must be regarded as an arbitrary definition.

3.5. Preliminary experiments

Constant outflow velocity

A series of preliminary experiments was undertaken for a constant outflow velocity to investigate the nature of the velocity field within the downdraft and the effect of nozzle height above the ground plane. Normalised velocity profiles are shown in Fig. 4, with the notation adopted for the normalization shown in Fig. 4a. Fig. 4b illustrates the results of the normalised streamwise velocity profiles obtained at various normalized distances (X/D) from the stagnation point for a nozzle height of 2D. In Fig. 4b the vertical axis represents the vertical height (Y) above the ground normalized by the height corresponding to half of the streamwise maximum velocity ($Y_{m/2}$). This normalization is common in terms of representing the flow field associated with a wall jet (see Wygnanski, *et al*. 1992). Also shown in Fig. 4b is the empirical function of Wood, *et al*. (2001) illustrating agreement of the current data with previous studies for values of $Y/Y_{m/2} > 0.2$. It is also



(a) Normalization notation. (b) Experimental data.

Fig. 4 Normalised streamwise velocity profiles under steady state conditions, H/D = 2.0

8IC5IFK5 actual figure p7

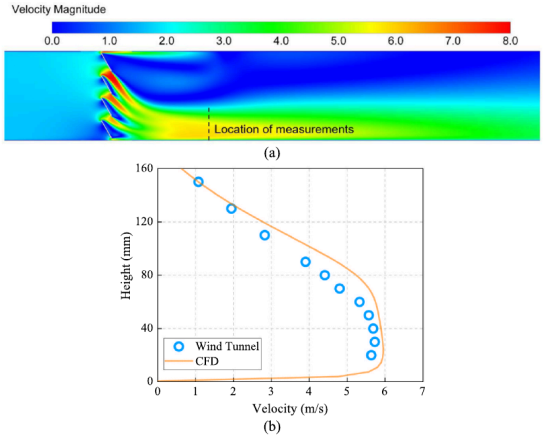


Fig. 15. Simulation of downburst outflow based on CFD with blade rotation angle of 60°: (a) CFD velocity contour; (b) comparison of vertical profiles between wind tunnel experiments and CFD simulations.

noted that the blades could be furtherly adjusted for the requirements of wind tunnel experiments with arbitrary length scales.

Fig. 18 presents the velocity vectors corresponding to two scales discussed in Fig. 17. The arrows in each subfigure are scaled and colored according to the wind velocity. Fig. 18(a) demonstrates the presence of a primary vortex at the upper of the test chamber due to the larger rotation of Blade 1 and Blade 2, directing more intense downburst airflow. This observation results in the peak of the nose-like wind velocity profiles at the elevation of 37 mm. However, a smaller primary vortex appears in Fig. 18(b) due to the slighter rotation of Blade 1 and Blade 2, and multiple flow structures converge at higher elevations. With the contribution of the anticlockwise rotation of Blade 4, the maximum velocity occurs at the elevation of 85 mm. Besides, Fig. 18 also presents the angle of attack profiles. As shown in Fig. 18(a), the angle of attack increases with height due to the significantly redirected flow, but maximum angle of attack is less than 2 deg. Similarly, the

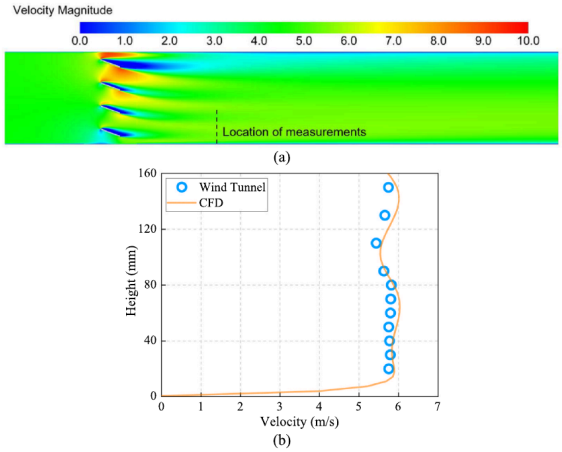


Fig. 16. Simulation of downburst outflow based on CFD with blade rotation angle of 20°: (a) CFD velocity contour; (b) comparison of vertical profiles between wind tunnel experiments and CFD simulations.

6X6ZP3YD actual figure p8

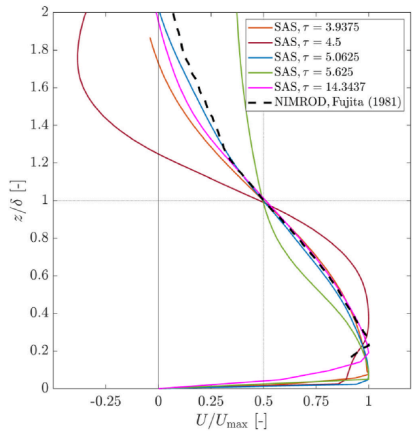


Fig. 15. Comparison of vertical profiles of radial velocity for dimensionless timesteps (τ) with the field measurements from the NIMROD project (Fujita, 1981).

- the flow within the bell-mouth is dominated by continuous unsteady separation of vortices from the high curvature of the nozzle, causing the interaction with the just-developed ring vortices.

4.3. Heights of the maximum radial velocity

Downburst winds can cause high-velocity winds in the near surface region, with potential to damage low-rise and mid-rise structures. Therefore, it is of great interest to analyze at which heights (z_{max}) radial velocities have their maximum values recorded throughout the downburst life cycle (*i.e.* the heights at which vertical profiles exhibit a peak as seen in Fig. 10). Fig. 20 shows the time history of heights at which the maximum radial velocities are recorded for $R/D = 1.2$. The *x*-axis shows the normalized time (τ), while the *y*-axis shows z_{max} normalized by the height at which the overall radial velocity maximum was observed in the experimental campaign (Z_{max}). Hereby, the experimental data is presented in terms of two-sided error bars centered around the average value of z_{max} observed across all twenty individual repetitions. The error bars hence represent the maximum and minimum observed height among the repetitions. The first parts of the signals (*i.e.* $\tau < 4$) can be disregarded from this analysis since the PV did not yet develop over $R/D = 1.2$ (resulting in low velocities). Generally, the measured mean z_{max} shows approximately constant values, but that is simply due to the high content of fluctuations (*i.e.* positive and negative values) contained within experimental repetitions which smooth the signal. Slight general trend of increasing measured mean of z_{max} is observed after the ring vortex passage ($\tau > 5$) that indicates the underlying tendency of individual repetitions of recording higher values of z_{max}. Conversely, both SAS and URANS data exhibit an oscillatory behavior with respect to measured mean data. These oscillations are generally associated with the passage of ring vortices. Moreover, prior and during the passage of ring vortices, z_{max} occurs at lower locations, while it is shifted upwards after the vortex passage. Overall, the height z_{max} at which the maximum radial velocity is recorded at particular R/D location varies throughout the downburst life cycle as a function of the passages of ring vortices.

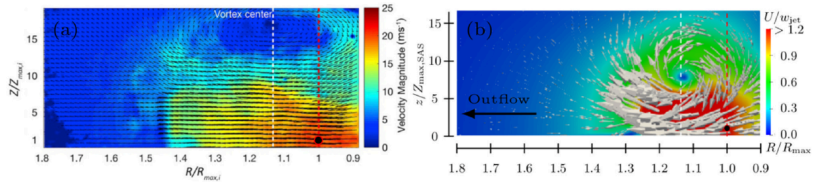


Fig. 16. Qualitative comparison of flow field during the maximum radial velocity occurrence between the SAS simulation and the PIV measurements by Junayed et al. (2019).

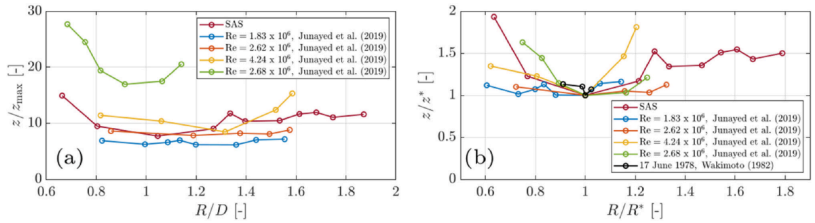


Fig. 17. Comparison in terms of vortex center locations of: (a) SAS and PIV measurements by Junayed et al. (2019), (b) SAS, PIV measurements of Junayed et al. (2019) and full-scale downburst event of 17 June 1978 by Wakimoto (1982).

36XAQH9L actual figure p14

AI-generated, not peer reviewed; exploratory trial, not a formal project closure.