NATHAZ AI LAB / TECHNICAL REPORT · EXPLORATORY TRIAL

L22.2 Strata + Qwen3.8-Flash-Next local inference (Colab A100)

Group First Lab

Status Promoted

Period 2026-10-13 00:15 — 2026-10-21 00:51

Stage conclusion

Project report

Strata + Qwen3.8-Flash-Next 本地推理（Colab A100）

目标

在 Colab A100 上实测 Strata（MIT，钉 v0.1.43）+ Qwen3.8-Flash-Next（125B MoE / 6B 激活，unsloth UD-IQ4_XS 约 93.7 GB）：能否跑起来、速度、成本、对我们有什么用。交付：可行性与实测表、日志路径、一句结论（能做到 / 只能做到低档 / 不值得）。

当前状态

结论（10-13 01:20，Lead 核过原始日志）：能做到。 Colab A100 high-mem 上 Strata v0.1.43 + UD-IQ4_XS 不降档跑通 32K；32K 输入首 token 约 10 s、读入约 2,990 tok/s、输出 35–59 tok/s；needle 3/3。代价是**每**

开一次新 Colab 会话都要约 40 分钟准备（约 4 CU），适合"批量处理一批长文档再关掉"，不适合当常驻服务。本轮花费约 5 CU（上限 30）。

可行性与实测

配置	是否跑起来	速度	成本	问题
Colab A100 high-mem 硬件探测（10-13）	是	—	<0.1 CU	必须带 `--high-mem`
Strata v0.1.43（commit）+ unsloth UD-IQ4_XS（rev，93.68 GB），32K 上下文	是，未降档	显存峰值 62.8 GiB/80；进程内存 7 GiB（权重靠 159 GiB 页缓存）	—	无官方预编译引擎，需现场编译
首次准备：下权重 + 编译 + 拉 MTP 5 GB + 打包	是	约 40 min（setup 1,796 s + 权重校验）	约 4 CU / 每个新会话	Colab 会话不留盘，每次重来；脚本把权重下了两遍（磁盘到 96%），下次用 `--gguf-dir`
引擎加载到可用	是	35 s	<0.1 CU	默认 8080 被 Colab 占用，须改端口（用 8090，绑 127.0.0.1）
短 prompt（34–48 tok）×3	是	首 token 0.4–0.7 s；输出 32–129 tok/s（中位 36）	合计 0.2 CU	输出速度靠 MTP 投机命中，波动大
8K（~7,860 tok）×3	是	首 token 4.0–4.2 s；读入 ~1,970 tok/s；输出 46–68 tok/s	同上	
32K（~30,190 tok）×3	是	首 token 10.1 s；读入 ~2,990 tok/s；输出 35–59 tok/s（中位 43）	同上	作者称 60–160 tok/s，我们长输入下只到其低端
needle 30.2K，10%/50%/90%	3/3 答对	首 token 10.1–10.5 s	同上	只是单针精确串检索，不代表长文理解
合计			**约 5 CU**（会话约 00:20–01:13；Gemini 报 4.76–5.65）	01:15 Lead 核 `colab ls`：无活动会话

许可（Lead 核原文，来自 HF Qwen/Qwen3.8-Flash-Next LICENSE）：MIT 式授权，须保留版权声明；月活 >1 亿或月收入 >2,000 万美元的商用产品须在界面标明模型名；做"模型即服务 / AI 办公编程助手"业务的商用须另取授权，但**不对第三方开放的内部使用不受此限**。我们实验室内部用没有障碍。

试过与结果

日期	做了什么	结果一句
10-13	Colab A100 high-mem 硬件探测	80 GB 显存 / 167 GB 内存 / 194 GB 盘 / CUDA 13.0
10-13	gpu-gemini 实测（ideas 缺凭据改派）	跑通，32K 输出 35–59 tok/s，needle 3/3，约 5 CU

Lead 核对记录：速度、needle 数字逐条对上 runner.log 与 server.log；更正 Gemini summary 三处——(1) "冷启动 35 s"只是引擎加载，新会话实际约 40 min；(2) 专家权重主要在显存缓存（server.log: 55.43 GiB），不是"全在系统内存"；(3) 第 2 次尝试的 8K 结果（首 token 0.08 s）是命中缓存，已被丢弃，最终表用第 3 次完整运行。

对我们的用处与不要做的事

- 有用：一次性批量处理长文档（规范、长论文、整批日志，≤32K token/份），数据不出 Google、无按 token 计费；也可做 bot 的离线备用推理。约 4 CU 开机费 + 每小时 5.4 CU，单批几十份长文档才划算。
- 不适合：常驻服务（Colab 会话会断、长时间无输出会断连）；超过 32K 的长文（本次未测）；替代平台主力模型。
- 不要做：不改平台默认模型；API 只绑 127.0.0.1，不开公网隧道；不用 `--dangerously-skip-permissions`；不向第三方提供推理服务（许可第 2 条）。

相关项目

- 子项目「文献库全文检索 + 风工程数据抽取」（10-13 由本节点讨论引出）已于 10-14 转正为平台工具 `pages`；10-16 02:38 台式机三来源约 55.6 万页全部交，等入库后 round5 盲测。详见。
- 本节点只管本地语言大模型推理（Strata + Qwen 及后续本地模型实测）。本地 LLM 接批量杂活的评测与结论在，本页的 run.py 与冷启动数字是其起点。

10-17 重启：Colab 冷启动缓解 + G4（Liang Hu 10-17）

- Liang Hu 问"Colab 无法常驻"后要求把缓解措施用上，试可用后转 ComputeOps 和各线 Lead。已派 ideas：比较缓存方案（工作站 小件 / Google Drive / 重下）把新会话准备时间从约 40 min 缩到多少；实测 Colab G4（顺带测 Strata v0.1.45 是否变快）。≤15 CU，写入。
- 保活工具 平台已有（处理无输出被收回、24 h 寿命提醒），直接用。

- Google Drive：10-17 07:5x Lead 实测 `colab drivemount`（CPU 会话 lead-drive-probe，已 stop）——每个新 Colab VM 都弹浏览器授权（临时凭据），不是一次性，bot 无人值守用不了；已告知 ideas 改用 工作站 小件缓存 + Hugging Face 重下，并单列"只有 Drive 才能省掉的部分"供 Liang Hu 判断。CLI 的 OAuth 令牌只有 drive.file 范围，未尝试把令牌带进 Colab（不外放凭据）。
- **10-17 G4 实测（ideas，Lead 核过）**： G4 = RTX PRO 6000 Blackwell 96 GB 显存、176 GB 内存、194 GB 盘、48 核；`--high-mem06_Logs/colab_persist/g4_20261017/strata-v0.1.45-sm120`，未验证可恢复）；大件（权重、MTP、打包物共约 100 GB 量级）只能放 Drive，待 rclone 授权。产物。
- **Drive 长期凭据**：Liang Hu 10-17 批准；rclone 限 drive.file 范围（决策）。08:13 第一次授权链接被 Lead 连通性测试误触作废；10-17 10:58 Liang Hu 完成授权（任意设备点 Google 链接、回传地址栏网址给 Lead）；工作站 （600）远端 `gdcache:` 可用，Drive 30 TiB 余 28.3 TiB， 已建、读写测试通过；授权日志已删。注意：drive.file 下能看到的是所有经 rclone 公共 client 建的文件（另见到 10-14 的 CRC_Archive）； rclone 公共 client_id 2026 年内退役，需改用自建 client_id（待办）。10-17 11:00 派 ideas： 大件存 Drive + 新会话恢复实测，本轮 ≤16 CU（项目累计上限 25）。
- **10-17 Drive 大件缓存实测（ideas）**： rclone 公共 client_id 被 Google 限流——77 MB 引擎上传 1.8 MB/s，1.5 GB 打包件 20 min 传不完、随后 `RATE_LIMIT_EXCEEDED`，连 工作站 下载都被拒。Drive 上只存了引擎和配置等小件；新会话恢复未测。约 7.8 CU（项目累计约 16.5/25）。结论：要用 Drive 必须换 Liang Hu 自建 OAuth client_id（已请 Liang Hu 建）； 先派 ideas 测"只缓存引擎、不经 Drive"能省多少（#下一单，≤7 CU）。
- **10-17 只缓存引擎实测（ideas，Lead 核过）**： 只存 77 MB 可执行文件不够——Strata setup.py 要同时看到 （记录源码哈希和显卡架构）才跳过编译，我们 工作站 上的缓存缺这个文件，所以照样重编译，省 0 分钟。另发现 v0.1.45 要用 `--gguf-dir` 指定已下好的权重，否则会重复下载。约 3.3 CU （项目累计约 19.8/25）。
- **下一步（Lead 定）**： 等 Liang Hu 建好自己的 OAuth client_id 后做最后一轮，两个会话一次做完：会话 A 完整准备一次，把整个 目录（含 BUILD.json）存 工作站、把打包件和 MTP 存 Drive；会话 B 全新开机只恢复、量准备时间并跑短 prompt 和 32K。预计约 8 CU，项目上限届时提到 30 CU。在此之前不再开 Colab。
- **10-17 17:0x 改用 Liang Hu 已有的授权通道**：台式机 rclone 远端 `gdrive`（Liang Hu 自建 OAuth client，drive.file，即 CRC 归档用的那个）复制到 工作站 （600）； 工作站 实测上传 9.6 MB/s、下载 31.5 MB/s、无限流。旧远端 `gdcache:`（公共 client，被限流）已删，其 里的测试缓存（引擎副本、配置、分词器文件，均可重建，引擎原件在 工作站）已清空。不再需要 Liang Hu 新建 client_id。派 ideas 最后一轮（会话 A 完整准备并存缓存，会话 B 全新恢复实测），≤10 CU，项目上限提到 30。
- **10-17 最后一轮（ideas，Lead 核过 setup 日志原句与 stop 记录）**： 缓存完整 （3 件 91.6 MB，含 BUILD.json，存 工作站 与 Drive）+ 打包件 1.5 GB + MTP 6.9 GB（Drive，共 8.5 GB）； 权重照常 HF 重下。全新 G4 会话：Drive 取回 142 s、HF 权重 384 s、setup 40 s（跳过编译和打包）、加载 150 s，可比阶段 1,907 s→716 s（约 32→12 min），分配到可用 14 min 15 s；短 prompt 和 30K 长文各 1 次正常。Colab↔Drive 上传 37–58 MB/s、下载 60–84 MB/s。本轮约 7.5 CU，项目累计约 27.3/30 CU。交接 已发平台 Lead 和 ComputeOps：ComputeOps 10-17 已记录； 承诺并入共享 （10-18 18:07 再核：README 仍是 10-17 18:12 版，已含 gdrive 一节与"两边不要重新授权"； 工作站 与台式机刷新令牌指纹相同（尚未分开）， Drive 访问正常； 10-17 22:20 Lead 复核已落地：README 已有 gdrive: 缓存一节与凭据规矩； 工作站 rclone.conf 18:10 由平台改动，仍 600、仅 gdrive 一个远端）， 工作站 rclone.conf 由平台收管（路径权限不变）， 平台将给 工作站 单独授权一份令牌以免与台式机互相失效。

- **10-21 总结与未来报告**：。L32.0 阶段 3c（10-18）选 Qwen3.8 作 v0 基座。
- **10-18 已转正**：Liang Hu 批准并入 L32 AI 教学实验室 · L32.0 自有教学大模型；交接已发，10-18 对方已收：放进 L32.0，排入阶段 3c（G4 用缓存起 Strata，与 gpt-oss-120b 同口径测 eval_v2/eval_v2h，≤10 CU，当天出结论定 v0 基座），缓存+保活采纳为默认，教学演示待 Liang Hu 定阶段 4/5。L22 不再派活，材料原地保留供只读引用。
- 10-18 Liang Hu：后续做教学实验应该很有用，要考虑用途和去处。Lead 写转正提案 （建议并入 L32.0 自有教学大模型），待 Liang Hu 批。Colab 余额 2,222 CU（10-18 查）。
- Liang Hu 有一张 RTX 5090 32 GB 可用（10-17），系统内存待问。

边界

- 只在 Colab 上做，不往 工作站 下载权重；不改平台默认模型；API 只绑 127.0.0.1；不用 `--dangerously-skip-permissions`；不保存任何 token。
- 核 Qwen Community License 1.0 原文；权重下载放后台、分段确认，防断连；用完必须 stop。

未决与下一步

- **搁置原因**：可行性问题已答完（能做到）；眼下没有一批具体的长文档任务需要它，单独维护不划算。
- **缺什么**：一个实际用例（例如一批 ≤32K 的规范/论文需要批量抽取，且不宜走外部 API）。
- **何时重启**：有上述用例时，复用 （改用 `--gguf-dir` 避免重复下权重），预算约 4 CU 开机 + 5.4 CU/h；若需 >32K 再加一档 64K 测试。
- ideas 凭据问题平台已确认修复（10-13 06:09 起正常，平台 Lead）；本任务已由 gpu-gemini 完成，不重派。
- 未送：这是工程可行性实测，不是科学结论；数字已由 Lead 逐条对原始日志。

文献依据

- （作者速度表与 needle 未独立复测；MODELS.md 把 UD-IQ4_XS 归 96 GB+ 内存档）

Liang Hu 注

Key figures